IIC 2433 Minería de Datos

https://github.com/marcelomendoza/IIC2433

Cierre de la clase 1 – Preprocesamiento de datos y PCA

Preprocesamiento de datos:

¿Cuál técnica usaré para codificar variables nominales?

¿Cuál técnica usaré para codificar variables ordinales?

¿Cuál función de distancia o similitud debo usar si tengo datos en alta dimensionalidad?

PCA:

¿Qué ocurre con la varianza acumulada en la medida que aumento el número de componentes principales?

¿Cómo determino el número de componentes que necesito para capturar el x% de la varianza de un dataset?

- t-SNE y UMAP -

Clase 2 – t-SNE y UMAP

Objetivos de la clase

- Reconocer las técnicas de visualización de datos t-SNE y UMAP.
- Comprender cómo funcionan estas técnicas.
- Distinguir entre una técnica de visualización y una de reducción de dimensionalidad.

Resultado de aprendizaje

Aplicar una tećnica de reducción de dimensionalidad y una de visualización a un dataset identificando diferencias y similitudes entre ellas.

Plan

- Sesión 1: clase convencional.
- Sesión 2: clase activa, resolverán un desafío en clases (actividad formativa en equipo).

Stochastic Neighbor Embedding (SNE)

Objetivo: Proyectar los datos a 2D o 3D para visualización.

Idea: Convertir distancias (Euclideanas) a probabilidades condicionales.

Kernel Gaussiano:

$$p_{j|i} = \frac{\exp\left(-\|x_i - x_j\|^2 / 2\sigma_i^2\right)}{\sum_{k \neq i} \exp\left(-\|x_i - x_k\|^2 / 2\sigma_i^2\right)}$$

Vecindario (parametrizable)

Definimos una proyección:

$$q_{j|i} = \frac{\exp\left(-\|y_i - y_j\|^2\right)}{\sum_{k \neq i} \exp\left(-\|y_i - y_k\|^2\right)}$$

Stochastic Neighbor Embedding (SNE)

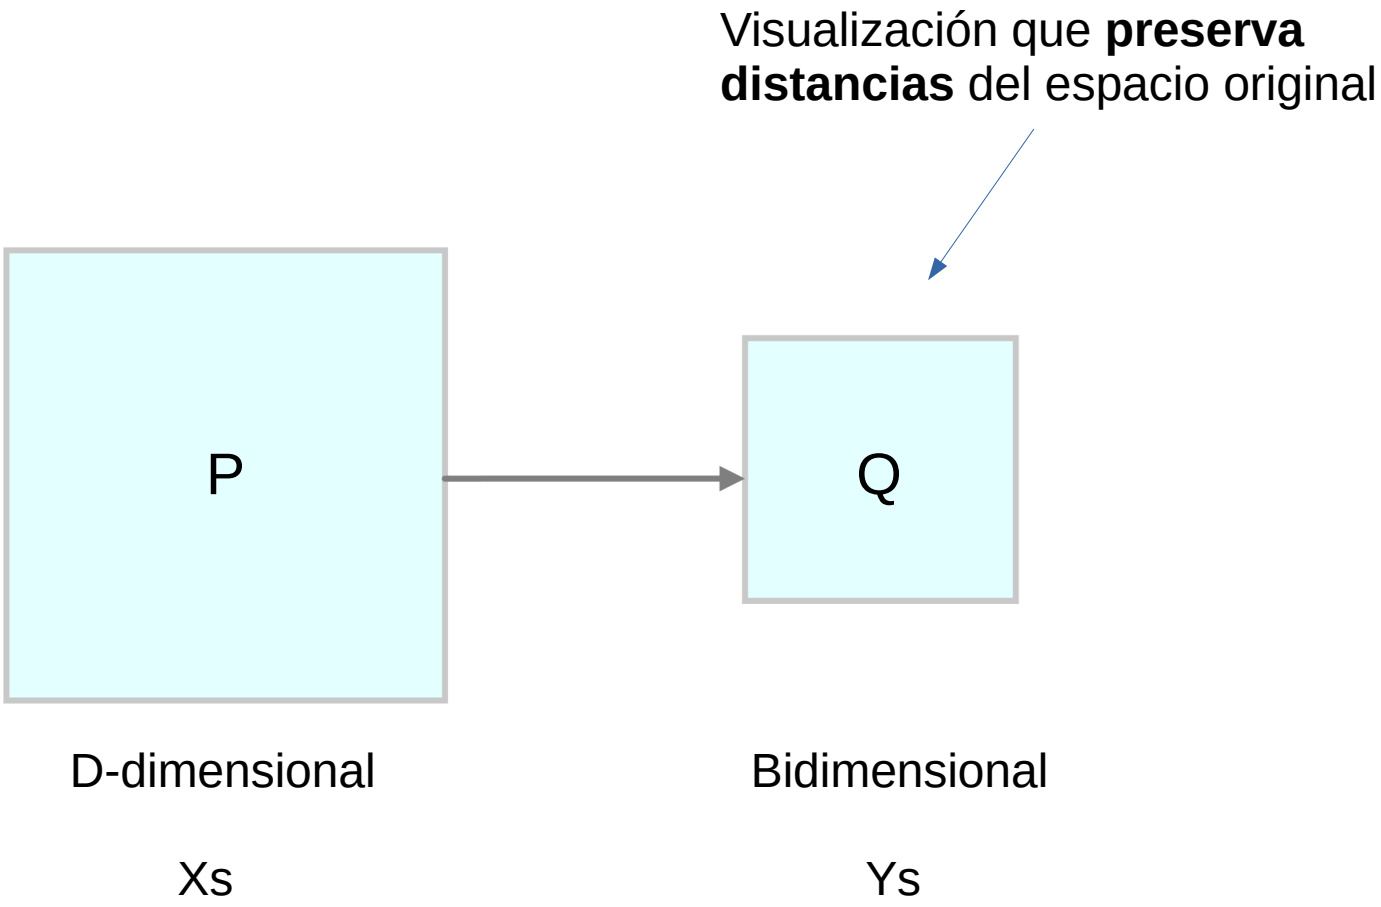

Stochastic Neighbor Embedding (SNE)

Hacemos lo mismo en un espacio de menor dimensionalidad (proyección):

distancia

probabilidad

$$q_{j|i} = \frac{\exp\left(-\|y_i - y_j\|^2\right)}{\sum_{k \neq i} \exp\left(-\|y_i - y_k\|^2\right)}$$

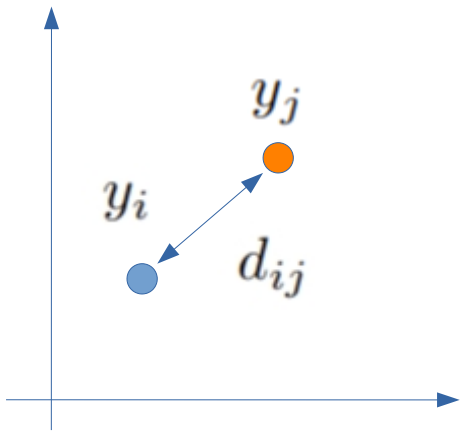

probabilidad

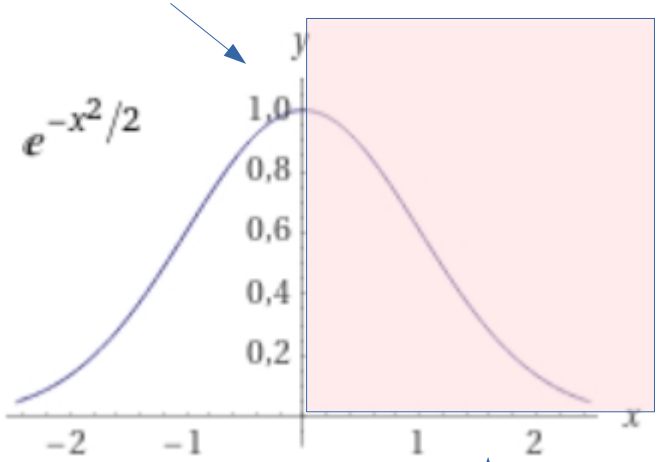

distancia

Stochastic Neighbor Embedding (SNE)

¿Cómo mido cuanto se parece el espacio original al proyectado?

Voy a comparar las distribuciones de probabilidad P y Q.

<u>Divergencia de Kullback-Leibler</u>:

$$C = \sum_i KL(P_i || Q_i) = \sum_i \sum_j p_{j|i} \log \frac{p_{j|i}}{q_{j|i}}$$

La divergencia es menor en la medida que ambas distribuciones son más parecidas.

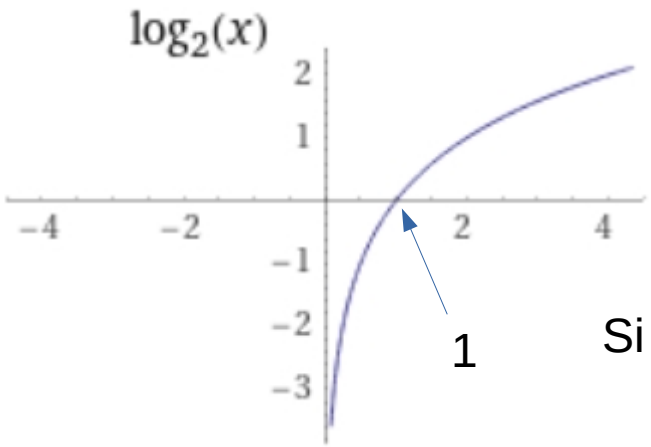

Si p~q → log p/q ~ 0

Model complexity

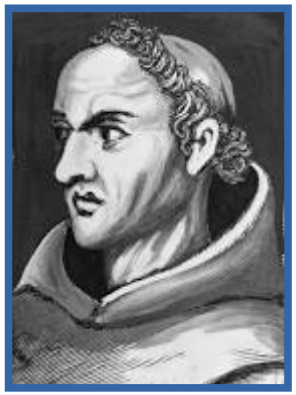

Principio (navaja de Ockham o principio de parsimonia)

“El modelo más simple es también el modelo más plausible”

Model complexity

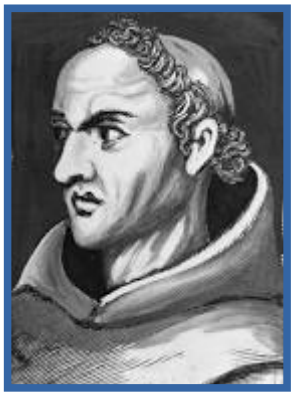

Principio (navaja de Ockham o principio de parsimonia)

"El modelo más simple es también el modelo más plausible"

Una medida de complejidad: Entropía (basada en familias de objetos)

$$H(P_i) = -\sum_j p_{j|i} \log_2 p_{j|i}.$$

Model complexity

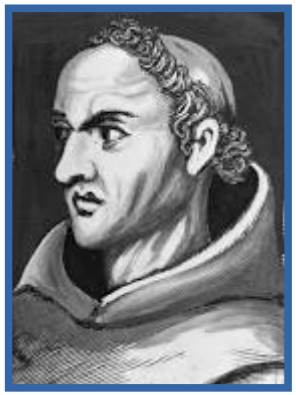

Principio (navaja de Ockham o principio de parsimonia)

"El modelo más simple es también el modelo más plausible"

Una medida de complejidad: Entropía (basada en familias de objetos)

$$H(P_i) = -\sum_j p_{j|i} \log_2 p_{j|i}.$$

Explicación: entropía como medida de información.

Lanzamos una moneda 4 veces. Posibles estados del ejercicio: $2 \cdot 2 \cdot 2 \cdot 2$

estados

$\log_2(16) = 4$ ← Bits para codificar los estados

ej. CSSC

Model complexity

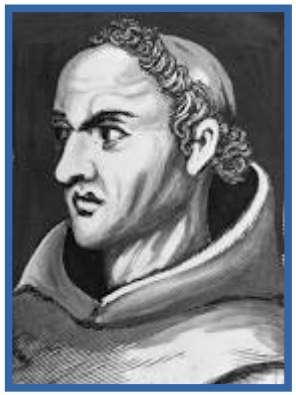

Principio (navaja de Ockham o principio de parsimonia)

"El modelo más simple es también el modelo más plausible"

Una medida de complejidad: Entropía (basada en familias de objetos)

$$H(P_i) = -\sum_j p_{j|i} \log_2 p_{j|i}.$$

Explicación: entropía como medida de información.

Lanzamos una moneda 4 veces. Posibles estados del ejercicio: $2 \cdot 2 \cdot 2 \cdot 2$

estados

Probabilidad de un resultado en particular (~U): $\log_2(16) = 4$ ← Bits para codificar los estados

ej. CSSC

P=1/#estados → $-\log_2(1/16) = 4$

Model complexity

Si los eventos no son equiprobables, debemos promediar:

$$H(P_i) = -\sum_j p_{j|i} \log_2 p_{j|i}.$$

Información codificada en el espacio original

Volvamos a SNE:

Me da el # de estados promedio (vecinos de cada punto)

El usuario define: $Perp(P_i) = 2^{H(P_i)}$

lo cual permite determinar σ_i (internamente).

Es decir, el usuario define la complejidad de la proyección, la cual es modelada en sigma!!!

Menos pares

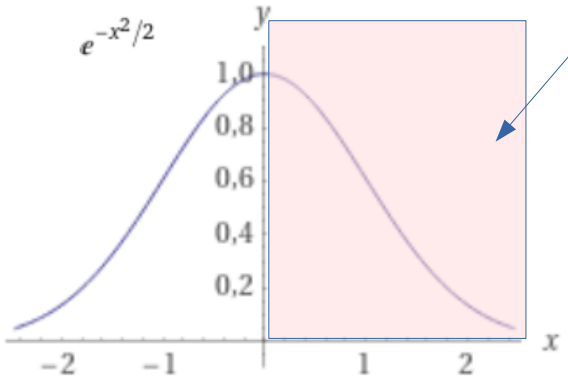

$\sigma = 1$

Más pares

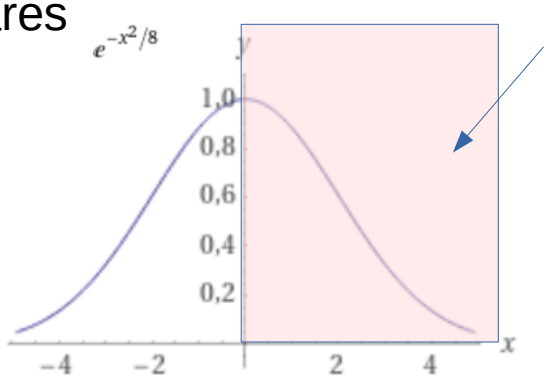

$\sigma = 2$

Stochastic Neighbor Embedding (SNE)

- Debemos calibrar el parámetro perplejidad.

- El parámetro nos indica la complejidad de la proyección:

  mayor perplejidad → menor parsimonia

- Mayor perplejidad → más vecinos → mayor sigma

Nota: En rigor usaremos una versión simétrica de SNE denominada t-SNE (reemplaza KL por Jensen-Shannon).

Uniform Manifold Approximation and Projection (UMAP)

Idea básica: UMAP calcula el grafo de vecinos, luego aprende un embedding a partir del grafo.

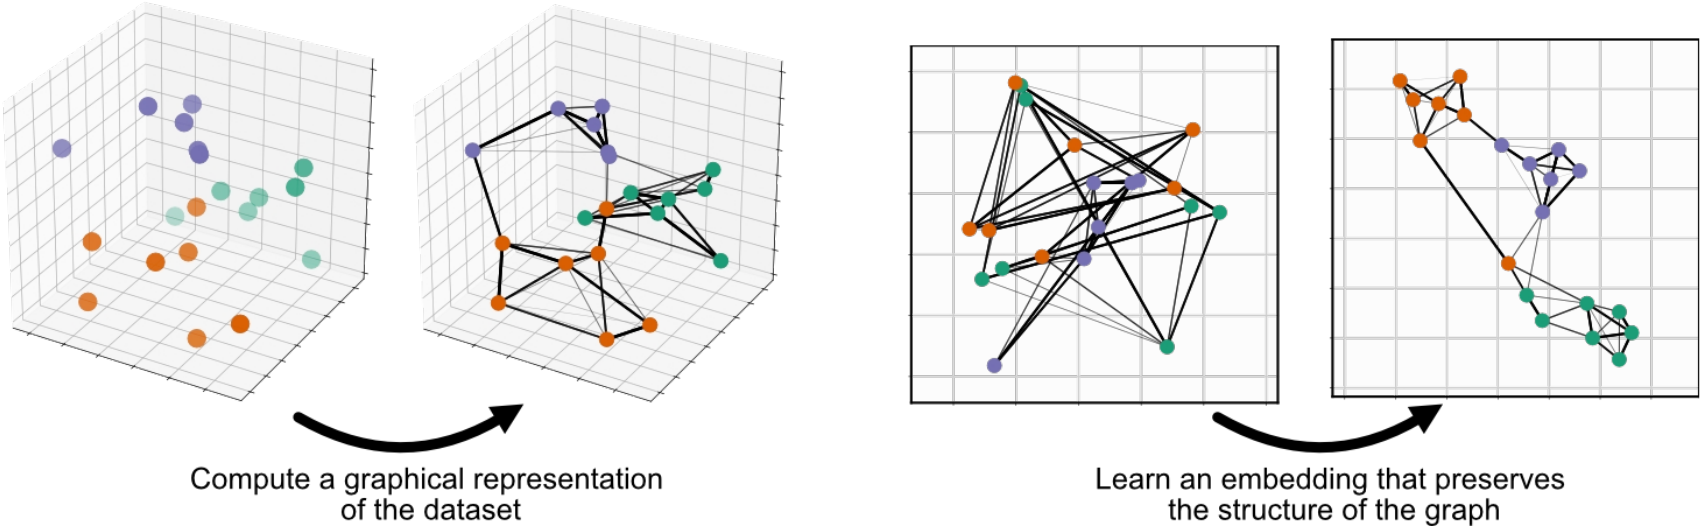

Uniform Manifold Approximation and Projection (UMAP)

UMAP paramétrico

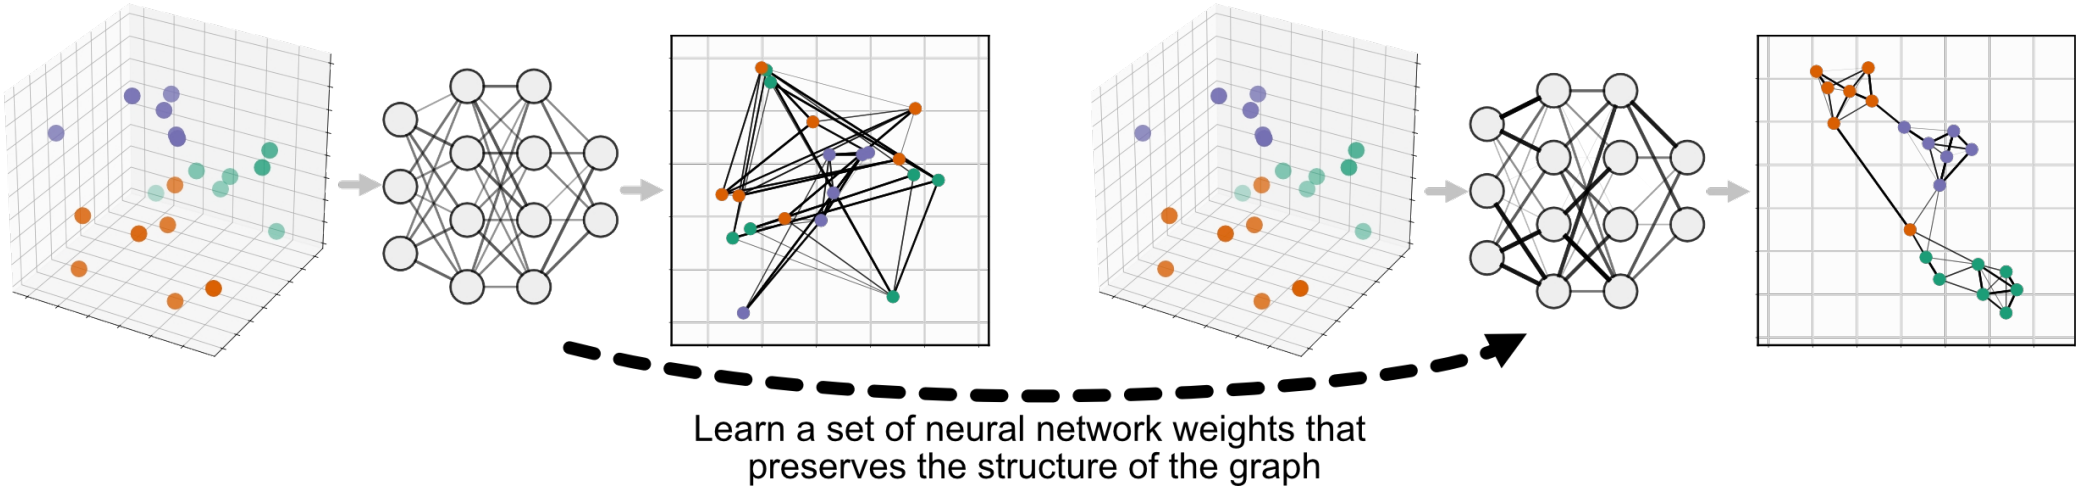

De esta forma, UMAP disminuye la dependencia de la técnica en relación con el parámetro de perplejidad.