



# IIC 2433 Minería de Datos

<https://github.com/marcelomendoza/IIC2433>

## Cierre de la clase 5 – Clustering basado en densidad



### **DBSCAN:**

¿Qué es transformación de dominio? ¿Cómo se usa en DBSCAN? ¿En cuál otra técnica vista en la asignatura se usa?

¿Qué es un k-dist plot? ¿Para qué se usa en DBSCAN?

### **HDBSCAN:**

¿Para qué se usa el minimum spanning tree en HDBSCAN?


¿Qué es el lambda de nacimiento y muerte?

¿Cómo se define la estabilidad de un cluster en HDBSCAN?

¿Cómo se desagrega un cluster usando la definición de estabilidad?

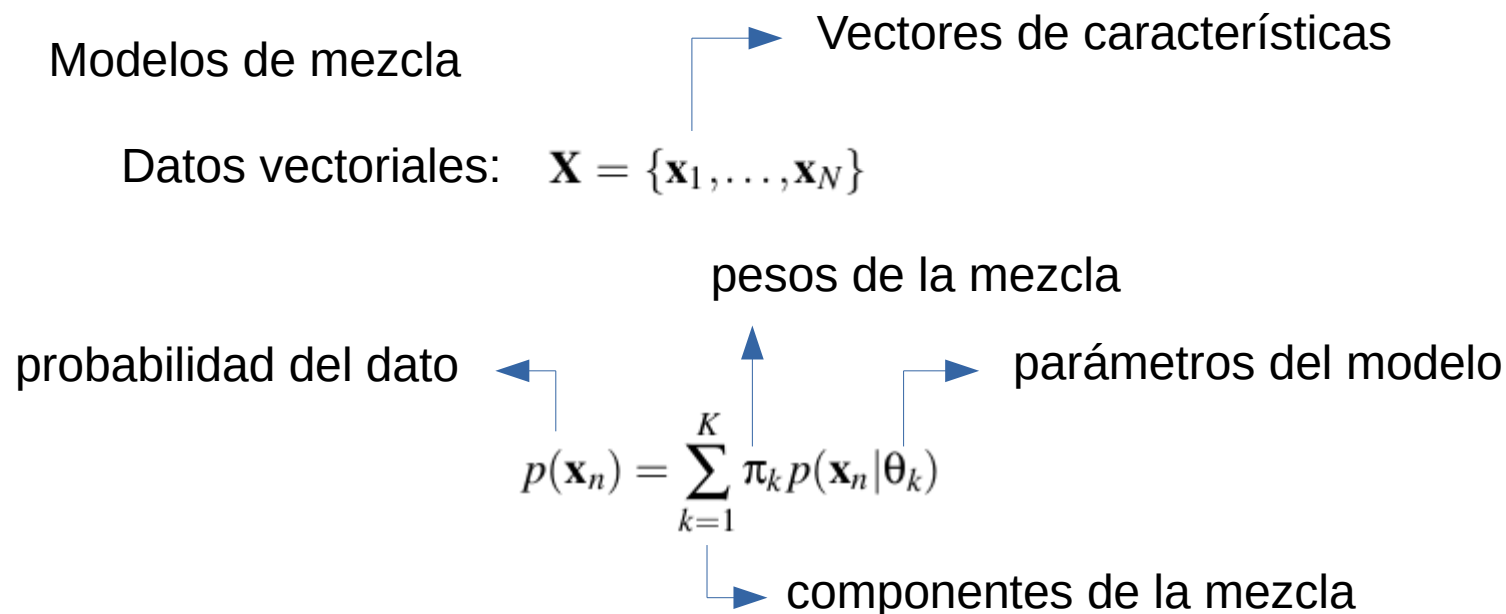
## Cierre de la clase 5 – Actividad formativa

¿Cuál cluster es más estable?



- GMM -

# Clustering probabilístico



Pesos de la mezcla:

$$0 \leq \pi_k \leq 1 \ (k = 1, \dots, K), \text{ y } \sum_{k=1}^K \pi_k = 1.$$

# Clustering probabilístico

Modelos de mezcla

$$\Theta = \{\pi_1, \dots, \pi_K, \theta_1, \dots, \theta_K\}$$

Inferencia de parámetros del modelo:  $\{\pi_k\}$  y  $\{\theta_k\}$ .

El número de componentes  $K$  se considera fijo (hiper-parámetro).

Asumimos que los datos son muestreados i.i.d., la probabilidad de generación del dataset es:

$$p(\mathbf{X}|\Theta) = \prod_{n=1}^N \sum_{k=1}^K \pi_k p(\mathbf{x}_n|\theta_k)$$

y en forma logarítmica:

$$\log p(\mathbf{X}|\Theta) = \sum_{n=1}^N \log \sum_{k=1}^K \pi_k p(\mathbf{x}_n|\theta_k).$$

Se usa el enfoque de máxima verosimilitud para inferencia:

$$\Theta_{ML} = \arg \max_{\Theta} \{\log p(\mathbf{X}|\Theta)\}$$



→ MLE: la mejor estimación es aquella que maximiza la probabilidad de generar las observaciones.

# Clustering probabilístico

## Modelos de mezcla



Bayes

$$\Theta_{ML} = \arg \max_{\Theta} \{\log p(\mathbf{X}|\Theta)\}$$

*Verosimilitud* (cuan probable es la evidencia condicionada al modelo)

*Prior* (nuestra creencia antes de observar la evidencia)

$$P(\Theta|X) = \frac{P(X|\Theta) \cdot P(\Theta)}{P(X)}$$

*Posterior* (cuan probable es el modelo condicionado a la evidencia)

*Marginal* (distribución de la evidencia, antes de pasar por el modelo)

# Clustering probabilístico

## Modelos de mezcla Gaussianas

Cada componente de la mezcla es una distribución Gaussiana.

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp\left\{-\frac{1}{2\sigma^2}(x-\mu)^2\right\}$$


media

varianza



Carl Gauss

Ej.:





# Clustering probabilístico

## Modelos de mezcla Gaussianas

Si  $\mathbf{x}$  es  $D$  dimensional:

$$\mathcal{N}(\mathbf{x}|\mu, \Sigma) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x}-\mu)^T \Sigma^{-1}(\mathbf{x}-\mu)\right\}$$

Determinante de  $\Sigma$

Matriz de covarianza  $D \times D$

Vector de medias  $D$ -dimensional


$$\Sigma = \begin{pmatrix} \sigma_{11}^2 & \sigma_{12} & \dots & \sigma_{1m} \\ \sigma_{21} & \sigma_{22}^2 & \dots & \sigma_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \dots & \sigma_{nm}^2 \end{pmatrix}$$



Carl Gauss

Ej.:

$$\begin{bmatrix} 0.25 & 0.3 \\ 0.3 & 1.0 \end{bmatrix}$$



$$\begin{bmatrix} 0.9 & 0.0 \\ 0.0 & 0.3 \end{bmatrix}$$

# Clustering probabilístico



Carl Gauss

## Modelos de mezcla Gaussianas

Cada componente está representada por los parámetros de una Gaussiana multivariada  $p(\mathbf{x}_k|\theta_k) = \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k)$ :

$$p(\mathbf{x}_n|\Theta) = p(\mathbf{x}_n|\pi, \mu, \Sigma) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k).$$

Dado  $\mathbf{X}$ , la función de verosimilitud queda dada por:

$$l(\Theta) = \log p(\mathbf{X}|\Theta) = \sum_{n=1}^N \log p(\mathbf{x}_n|\Theta) = \sum_{n=1}^N \log \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k).$$

Los parámetros del modelo son  $\pi_k$ ,  $\mu_k$ , y  $\Sigma_k$ .

Inferencia: basada en algoritmo Expectation - Maximization (EM).

---

**Algorithm**    EM for Gaussian Mixtures

---

Given a set of data points and a Gaussian mixture model, the goal is to maximize the log-likelihood with respect to the parameters.

1: Initialize the means  $\mu_k^0$ , covariances  $\Sigma_k^0$ , and mixing probabilities  $\pi_k^0$ .

2: **E-step:** Compute

$$\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)}.$$

3: **M-step:** Compute


$$\Sigma_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T}{\sum_{n=1}^N \gamma(z_{nk})}, \quad \mu_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n}{\sum_{n=1}^N \gamma(z_{nk})}, \quad \pi_k = \frac{\sum_{n=1}^N \gamma(z_{nk})}{N}$$

4: Compute the log-likelihood using  $\sum_{n=1}^N \log \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)$ .

---


Inferencia: basada en algoritmo Expectation - Maximization (EM).

Algoritmo EM:



Initialize  $\mu_k^0, \Sigma_k^0$ , and  $\pi_k^0$ .

**E-step**




$$\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)}$$

$$\Sigma_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T}{\sum_{n=1}^N \gamma(z_{nk})}$$


$$\mu_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n}{\sum_{n=1}^N \gamma(z_{nk})}$$

$$\pi_k = \frac{\sum_{n=1}^N \gamma(z_{nk})}{N}$$

**E-step**




**M-step**



datos|distribución

distribución|datos



Iterar hasta converger

¿Cuántas componentes necesita la mezcla?

**Criterio de información de Akaike (AIC):** maneja un tradeoff (diferencia) entre la bondad de ajuste del modelo (L) y la complejidad del modelo (k).

$$AIC = 2k - 2 \ln(L)$$


Si existe un balance entre la complejidad y la verosimilitud,  $AIC \rightarrow 0$ .

¿Cuántas componentes necesita la mezcla?

**Criterio de información de Akaike (AIC):** maneja un tradeoff (diferencia) entre la bondad de ajuste del modelo (verosimilitud) y la complejidad del modelo (k).

$$AIC = 2k - 2 \ln(L)$$


Si existe un balance entre la complejidad y la verosimilitud,  $AIC \rightarrow 0$ .




Buscar el mínimo

- UC - M. Mendoza -


## La idea del modelo generativo



## La idea del modelo generativo



Muestreo desde  $Z$   
(el modelo)



$(3.5, -0.9)$



- ANEXO -

MLE: debemos calcular las derivadas de  $\log p(\mathbf{X}|\pi, \mu, \Sigma)$  w. r. t.  $\pi_k$ ,  $\mu_k$ , y  $\Sigma_k$ .

$$l(\Theta) = \log p(\mathbf{X}|\Theta) = \sum_{n=1}^N \log p(\mathbf{x}_n|\Theta) = \sum_{n=1}^N \log \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k).$$

$\frac{d}{dx}(\log(x)) = \frac{1}{x}$

$\frac{d}{dx}(\exp(f(x))) = e^{f(x)} f'(x)$

posterior

$$\frac{\partial l}{\partial \mu_k} = \frac{\sum_{n=1}^N \frac{\pi_k \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n|\mu_j, \Sigma_j)} \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)}{\sum_{n=1}^N \gamma(z_{nk}) \Sigma_k^{-1} (\mathbf{x}_n - \mu_k)} = 0$$

$$\frac{\partial \mathbf{L}}{\partial \mu} = -\frac{1}{2} \left( \frac{\partial (\mathbf{y} - \mu)' \Sigma^{-1} (\mathbf{y} - \mu)}{\partial \mu} \right)$$

$$= -\frac{1}{2} (-2 \Sigma^{-1} (\mathbf{y} - \mu))$$

$$= \Sigma^{-1} (\mathbf{y} - \mu)$$

Análogamente, obtenemos:

$$\Sigma_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \mu_k) (\mathbf{x}_n - \mu_k)^T}{\sum_{n=1}^N \gamma(z_{nk})}$$

$$\mu_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n}{\sum_{n=1}^N \gamma(z_{nk})}$$

$$\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n|\mu_j, \Sigma_j)}$$

MLE: debemos calcular las derivadas de  $\log p(\mathbf{X}|\pi, \mu, \Sigma)$  w. r. t.  $\pi_k$ ,  $\mu_k$ , y  $\Sigma_k$ .

... falta un poco:

se agrega ya que los  $\pi_k$  deben ser positivos y sumar 1.

$$\log p(\mathbf{X}|\pi, \mu, \Sigma) + \lambda \left( \sum_{k=1}^K \pi_k - 1 \right).$$

$$\pi_k = \frac{\sum_{n=1}^N \gamma(z_{nk})}{N}$$