IIC 2433 Minería de Datos

https://github.com/marcelomendoza/IIC2433

Cierre de la clase 6 – GMM

Modelos de mezclas:

¿En qué se basa el principio de máxima verosimilitud?

¿Qué es una probabilidad *posterior* según Bayes?

GMM:

¿Qué modela la matriz de covarianza en una GMM? ¿Qué implica una entrada no diagonal?

¿Por qué el vector de medias puede aproximar un dato?

Si tengo 400 ejemplos ¿Cuántas Gaussianas pueden aproximar sin pérdida el dataset?

Cierre de la clase 6 – Actividad formativa

Si tengo dos datos ¿Cómo aproxima GMM a los ejemplos?

mezcla

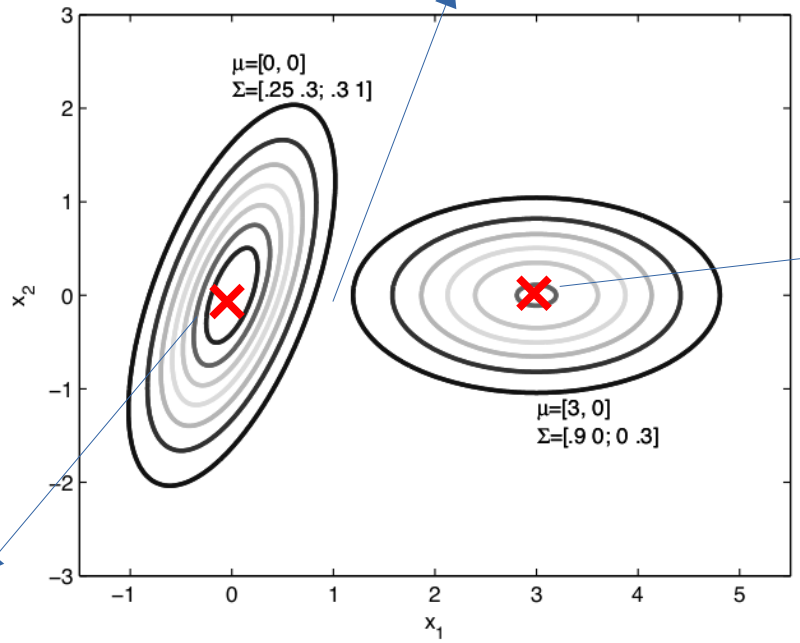

Dato: ✕

- Asociaciones -

Asociación

$$\{\texttt{Diapers}\} \longrightarrow \{\texttt{Beer}\}.$$

- Indica que si ocurre el antecedente, es probable que ocurra el consecuente.

- Usualmente involucran variables categóricas nominales.

- Se consolidan en reglas, las cuales usan {} para indicar asociaciones entre conjuntos denominados **itemsets**.

- En el ejemplo, ambos conjuntos son de cardinalidad 1.

- La asociación entre dos variables es un primer paso hacia la causalidad ya que define una relación de antecedente y consecuente.

- La asociación no necesariamente implica causa y efecto.

Reglas de Asociación

Datos:

TID	Items
1	{Bread, Milk}
2	{Bread, Diapers, Beer, Eggs}
3	{Milk, Diapers, Beer, Cola}
4	{Bread, Milk, Diapers, Beer}
5	{Bread, Milk, Diapers, Cola}

Regla: $\{\texttt{Diapers}\} \longrightarrow \{\texttt{Beer}\}$

Representación:

TID	Bread	Milk	Diapers	Beer	Eggs	Cola
1	1	1	0	0	0	0
2	1	0	1	1	1	0
3	0	1	1	1	0	1
4	1	1	1	1	0	0
5	1	1	1	0	0	1

Reglas de Asociación

Datos:

TID	Items
1	{Bread, Milk}
2	{Bread, Diapers, Beer, Eggs}
3	{Milk, Diapers, Beer, Cola}
4	{Bread, Milk, Diapers, Beer}
5	{Bread, Milk, Diapers, Cola}

Regla: $\{\texttt{Diapers}\} \longrightarrow \{\texttt{Beer}\}$

Representación:

TID	Bread	Milk	Diapers	Beer	Eggs	Cola
1	1	1	0	0	0	0
2	1	0	1	1	1	0
3	0	1	1	1	0	1
4	1	1	1	1	0	0
5	1	1	1	0	0	1

Items: $I = \{i_1, i_2, \ldots, i_d\}$; transacciones: $T = \{t_1, t_2, \ldots, t_N\}$

Soporte de un ítemset: $\sigma(X) = \left|\{t_i | X \subseteq t_i,\ t_i \in T\}\right|$

En cuántas transacciones ocurre X

Reglas de Asociación

Una regla de asociación es una implicancia $X \longrightarrow Y$ tal que $X \cap Y = \emptyset$.

Se definen:

$$\text{Support, } s(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{N};$$

$$\text{Confidence, } c(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)}.$$

transacciones

Reglas de Asociación

Una regla de asociación es una implicancia $X \longrightarrow Y$ tal que $X \cap Y = \emptyset$.

Se definen:

$$\text{Support, } s(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{N};$$

$$\text{Confidence, } c(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)}.$$

transacciones

Estrategia para generación de reglas:

1. Búsqueda de ítemsets frecuentes.
2. Generación de reglas candidatas a partir de ítemsets frecuentes.

Buscar asociaciones puede ser muy ineficiente. La eficiencia de la búsqueda es un tema crítico en reglas de asociación.

Principio Apriori

Si un itemset es frecuente, todos sus subconjuntos son frecuentes.

Reglas de Asociación

Principio Apriori:

Estructura de subconjuntos (*lattice*)

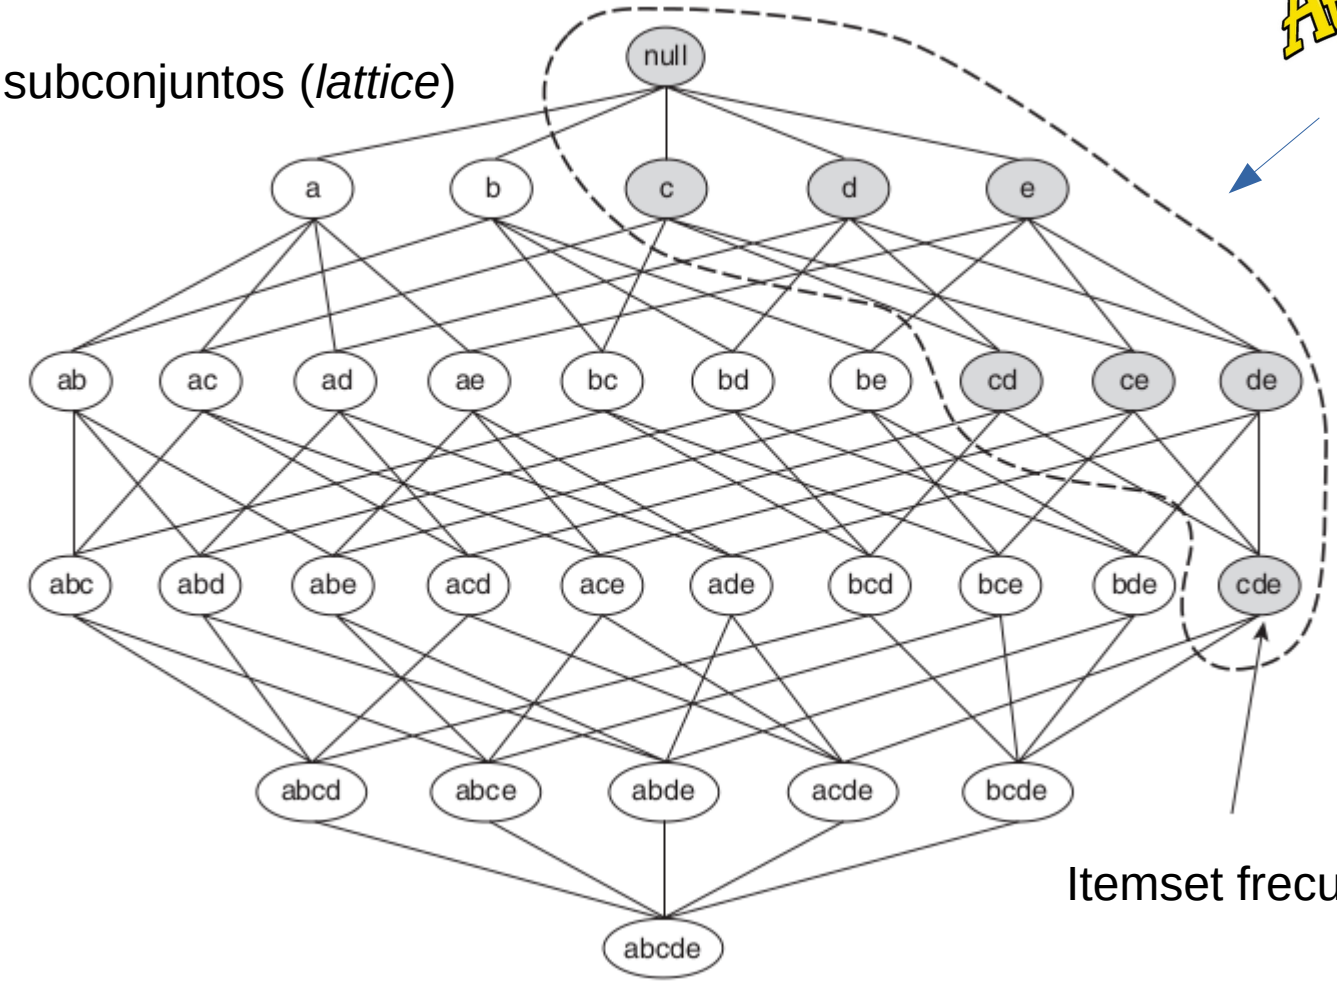

Itemset frecuente

Reglas de Asociación

<u>Principio de monotonicidad</u>: $\forall X, Y \in J: \ (X \subseteq Y) \longrightarrow f(Y) \leq f(X),$

Reglas de Asociación

<u>Principio de monotonicidad</u>: $\forall X, Y \in J: \ (X \subseteq Y) \longrightarrow f(Y) \leq f(X),$

Si este itemset no es frecuente ...

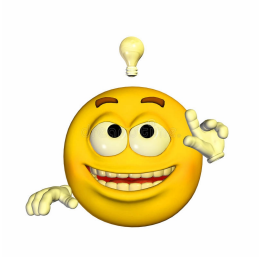

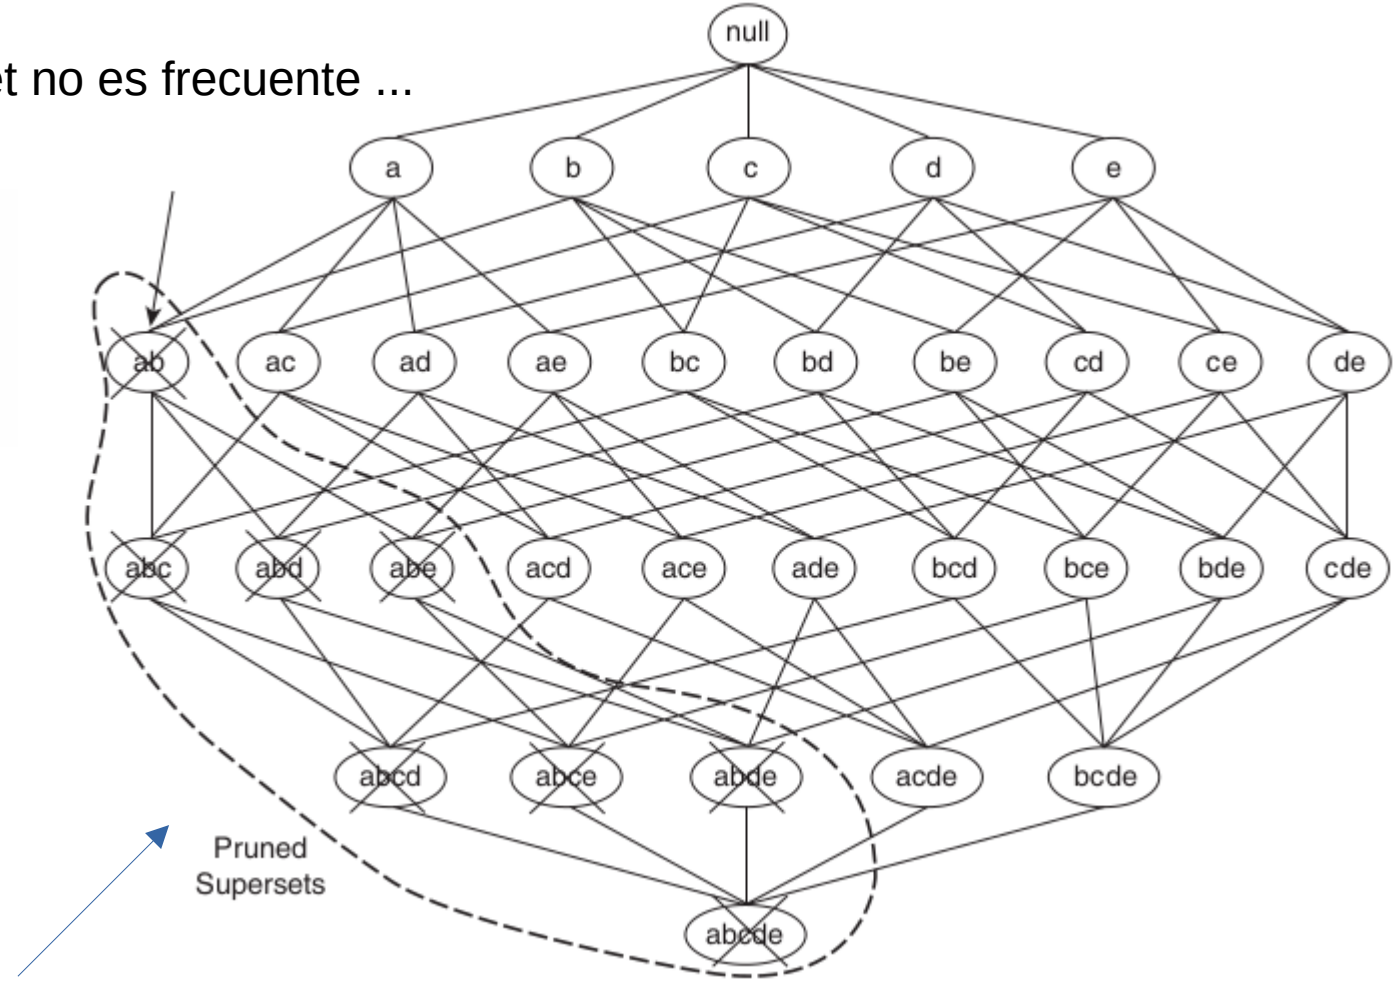

… estos tampoco son frecuentes.

Reglas de Asociación

Principio de monotonicidad: $\forall X, Y \in J: \ (X \subseteq Y) \longrightarrow f(Y) \leq f(X),$

Itemset no frecuente

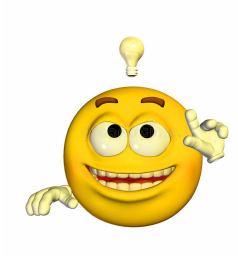

Podemos podar

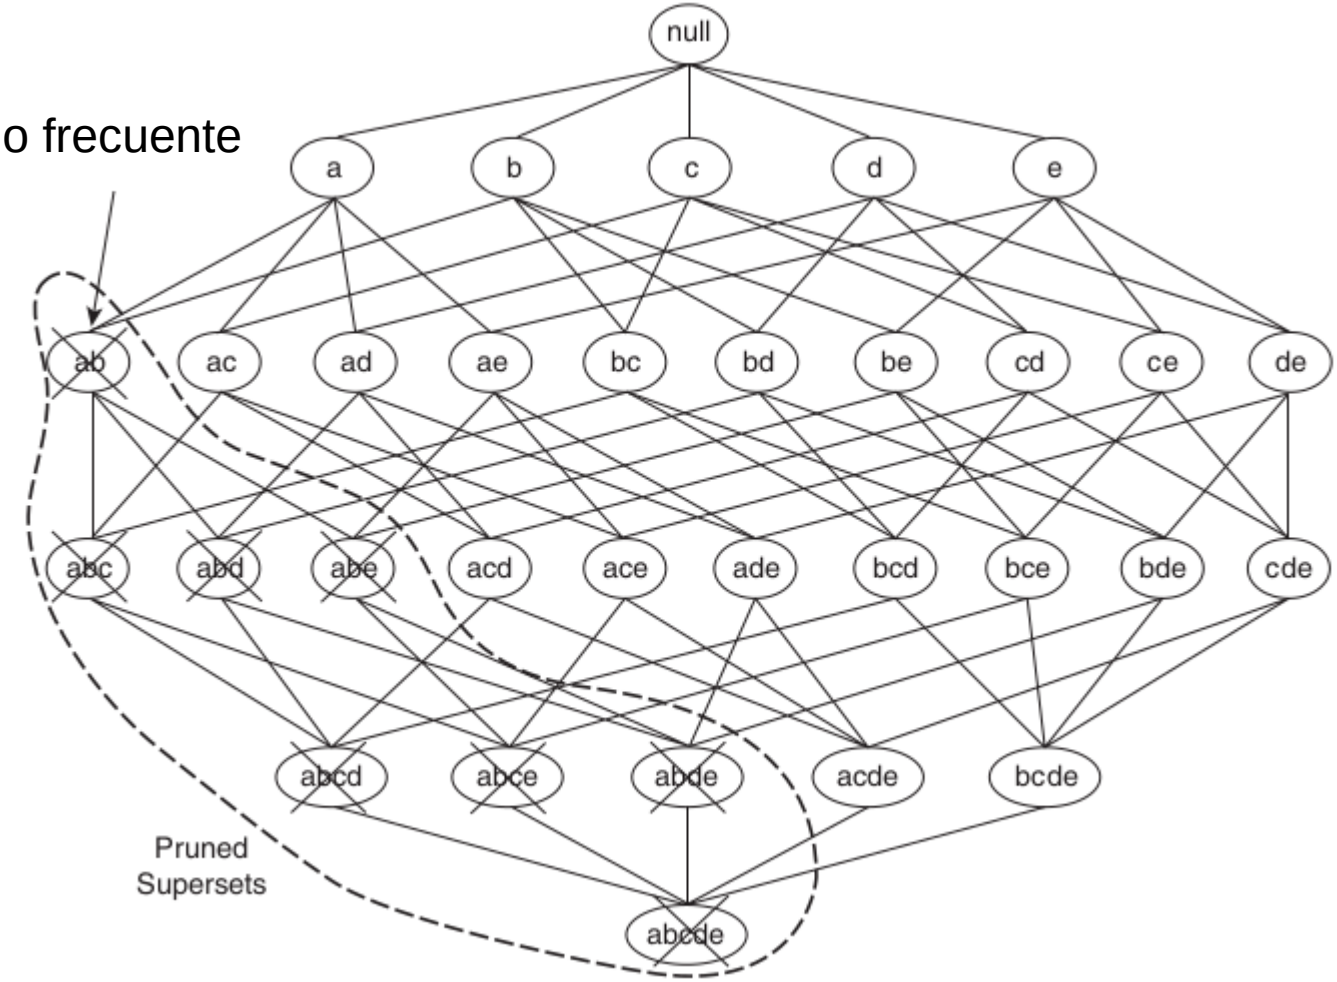

Reglas de Asociación

<u>Uso algorítmico del principio de monotonicidad</u>: Buscamos por orden creciente de cardinalidad:

Candidate 1-Itemsets

Item	Count
Beer	3
Bread	4
Cola	2
Diapers	4
Milk	4
Eggs	1

Minimum support count = 3

Candidate 2-Itemsets

Itemset	Count
{Beer, Bread}	2
{Beer, Diapers}	3
{Beer, Milk}	2
{Bread, Diapers}	3
{Bread, Milk}	3
{Diapers, Milk}	3

Itemsets removidos

Candidate 3-Itemsets

Itemset	Count
{Bread, Diapers, Milk}	3

Reglas de Asociación

<u>Uso algorítmico del principio de monotonicidad</u>: Buscamos por orden creciente de cardinalidad:

Candidate 1-Itemsets

Item	Count
Beer	3
Bread	4
Cola	2
Diapers	4
Milk	4
Eggs	1

Minimum support count = 3

Candidate 2-Itemsets

Itemset	Count
{Beer, Bread}	2
{Beer, Diapers}	3
{Beer, Milk}	2
{Bread, Diapers}	3
{Bread, Milk}	3
{Diapers, Milk}	3

Itemsets removidos

Candidate 3-Itemsets

Itemset	Count
{Bread, Diapers, Milk}	3

Reglas de Asociación

Ahora vamos a generar reglas a partir de itemset frecuentes.

Recordar:

$$\text{Support, } s(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{N};$$

$$\text{Confidence, } c(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)}.$$

Principio de monotonicidad: $\forall X, Y \in J: \ (X \subseteq Y) \longrightarrow f(Y) \leq f(X),$

Si $\tilde{X} \subseteq X$, $\sigma(X) \leq \sigma(X')$, luego $\frac{\sigma(X \cup Y)}{\sigma(X)} \geq \frac{\sigma(X \cup Y)}{\sigma(X')}$.

Reglas de Asociación

Ahora vamos a generar reglas a partir de itemset frecuentes.

Recordar:

$$\text{Support, } s(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{N};$$

$$\text{Confidence, } c(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)}.$$

Principio de monotonicidad: $\forall X, Y \in J: \ (X \subseteq Y) \longrightarrow f(Y) \leq f(X),$

Si $\tilde{X} \subseteq X$, $\sigma(X) \leq \sigma(X')$, luego $\frac{\sigma(X \cup Y)}{\sigma(X)} \geq \frac{\sigma(X \cup Y)}{\sigma(X')}$.

Atención Atención

Si una regla $X \longrightarrow Y - X$ no satisface un umbral de confianza, entonces toda regla de la forma $X' \longrightarrow Y - X'$, donde $\tilde{X} \subseteq X$, no puede satisfacer el umbral de confianza.

Reglas de Asociación

Si una regla $X \longrightarrow Y - X$ no satisface un umbral de confianza, entonces toda regla de la forma $X' \longrightarrow Y - X'$, donde $\tilde{X} \subseteq X$, no puede satisfacer el umbral de confianza.

Regla de baja confianza

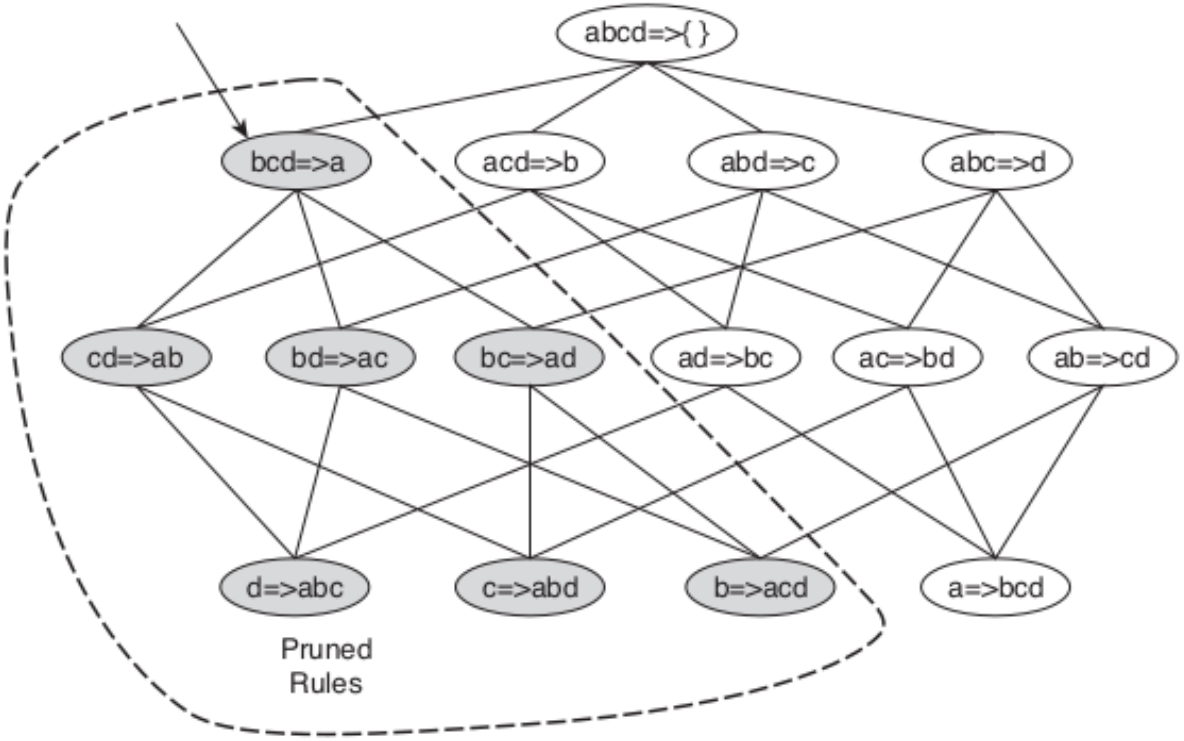

Reglas de Asociación

Si una regla $X \longrightarrow Y - X$ no satisface un umbral de confianza, entonces toda regla de la forma $X' \longrightarrow Y - X'$, donde $\tilde{X} \subseteq X$, no puede satisfacer el umbral de confianza.

Regla de baja confianza

Podemos podar

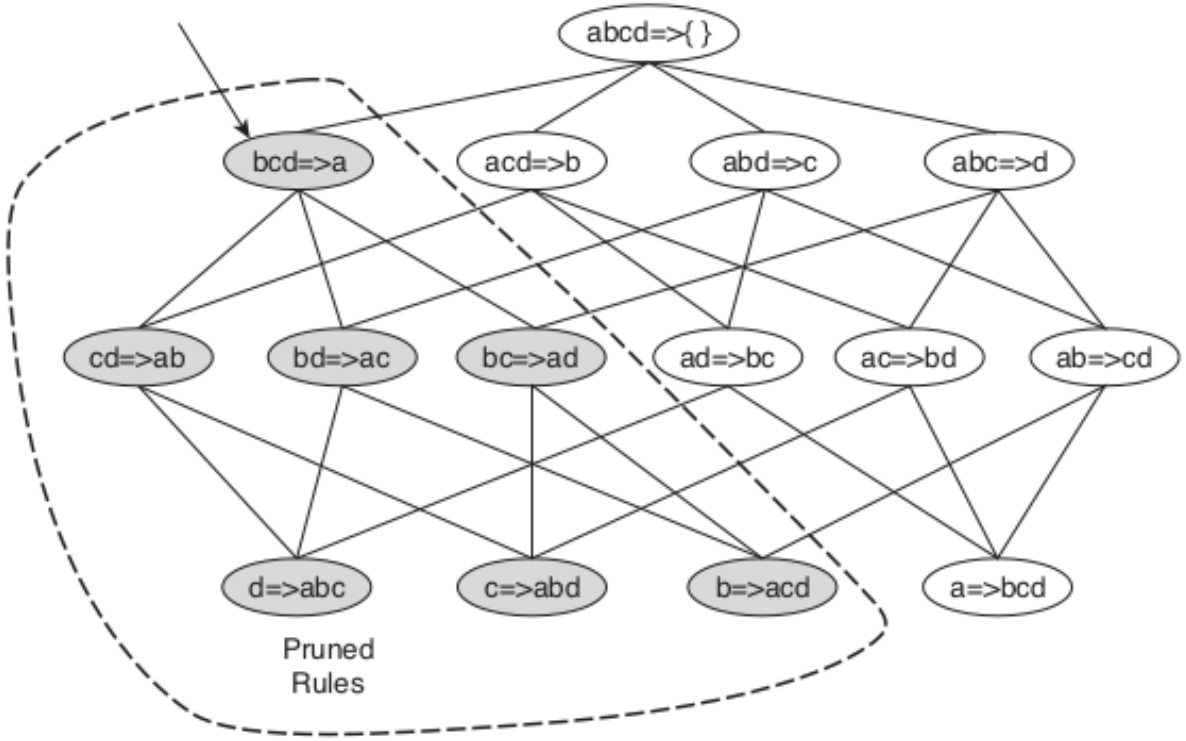

Reglas de Asociación

Si una regla $X \longrightarrow Y - X$ no satisface un umbral de confianza, entonces toda regla de la forma $X' \longrightarrow Y - X'$, donde $\tilde{X} \subseteq X$, no puede satisfacer el umbral de confianza.

Regla de baja confianza

Buscar aumentando el tamaño del consecuente

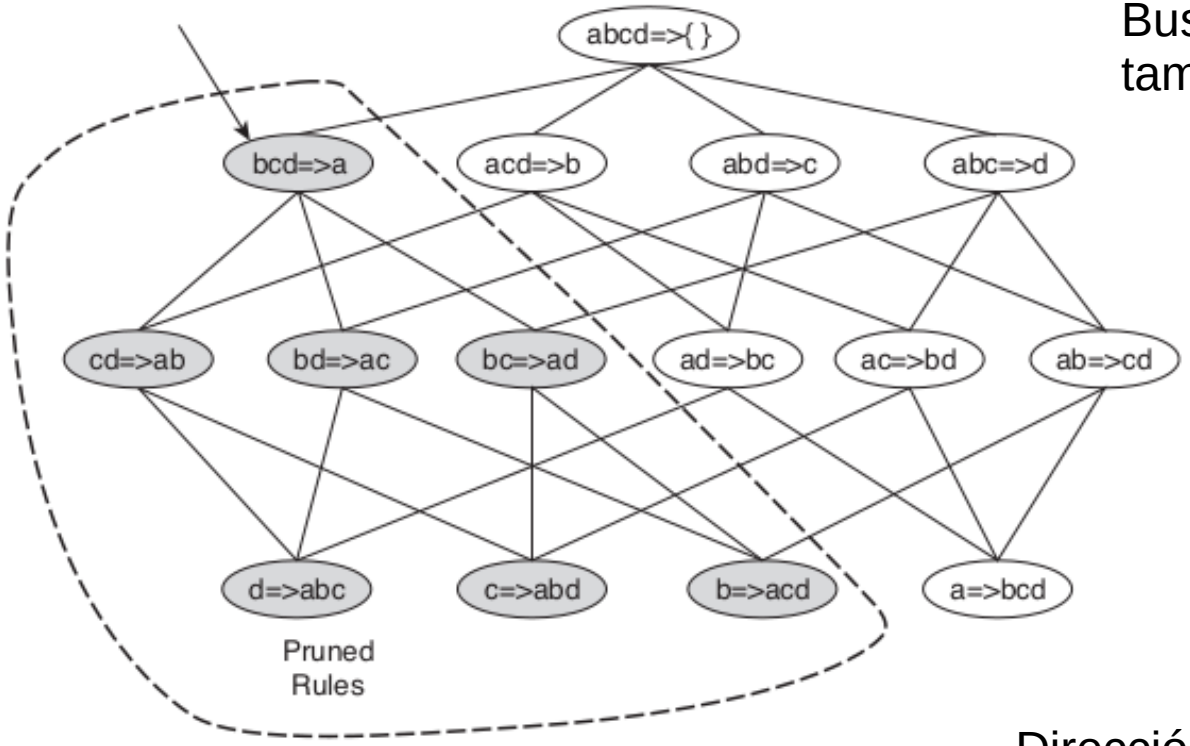

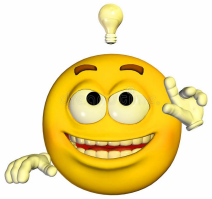

Podemos podar

Dirección de búsqueda

Lift

Evaluación de reglas de asociación ¿Qué tan relevantes son?

Recordar:

$$\text{Support, } s(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{N};$$

$$\text{Confidence, } c(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)}.$$

Es decir, podríamos evaluar las reglas sobre la base de las métricas que usamos para encontrarlas.

Limitación de estas métricas: Ítems frecuentes inflan la confianza.

Ejemplo: {pan} → {leche}: soporte 0.4, confianza 0.8. Si P(leche) = 0.9, la regla no es útil (comprar pan no predice comprar leche mejor que el azar).

Lift

Evaluación de reglas de asociación ¿Qué tan relevantes son?

Recordar:

$$\text{Support, } s(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{N};$$

$$\text{Confidence, } c(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)}.$$

Es decir, podríamos evaluar las reglas sobre la base de las métricas que usamos para encontrarlas.

Limitación de estas métricas: Ítems frecuentes inflan la confianza.

Ejemplo: {pan} → {leche}: soporte 0.4, confianza 0.8. Si P(leche) = 0.9, la regla no es útil (comprar pan no predice comprar leche mejor que el azar).

Una métrica que corrige esto es lift:

$$\text{lift}(X \Rightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X) \cdot \sigma(Y)}$$

Lift mide si la co-ocurrencia de X e Y es mayor de lo esperado bajo independencia. Usarlo para descartar reglas con confianza alta y lift ~ 0.

- ANEXO -

Reglas de Asociación

Para k = 2 no necesitamos algoritmo

Algorithm Rule generation of the *Apriori* algorithm.

```
for each frequent k-itemset f_k, k ≥ 2 do
    H_1 = {i | i ∈ f_k}        {1-item consequents of the rule.}
    call ap-genrules(f_k, H_1.)
end for
```

Algorithm Procedure ap-genrules(f_k, H_m).

```
k = |f_k|    {size of frequent itemset.}
m = |H_m|    {size of rule consequent.}
if k > m + 1 then
    H_{m+1} = apriori-gen(H_m).
    for each h_{m+1} ∈ H_{m+1} do
        conf = σ(f_k)/σ(f_k − h_{m+1}).
        if conf ≥ minconf then
            output the rule (f_k − h_{m+1}) ⟶ h_{m+1}.
        else
            delete h_{m+1} from H_{m+1}.
        end if
    end for
    call ap-genrules(f_k, H_{m+1}.)
end if
```

El antecedente tendrá al menos un ítem

Aumento el consecuente en 1

$$\frac{\sigma(X \cup Y)}{\sigma(X)}.$$

Una vez terminamos la verificación, continuamos recursivamente.

Termina cuando H_{m+1} es vacío.