



IIC 2433 Minería de Datos

<https://github.com/marcelomendoza/IIC2433>

Cierre de la clase 6 – GMM



Modelos de mezclas:

¿En qué se basa el principio de máxima verosimilitud?

¿Qué es una probabilidad *posterior* según Bayes?

GMM:

¿Qué modela la matriz de covarianza en una GMM? ¿Qué implica una entrada no diagonal?

¿Por qué el vector de medias puede aproximar un dato?

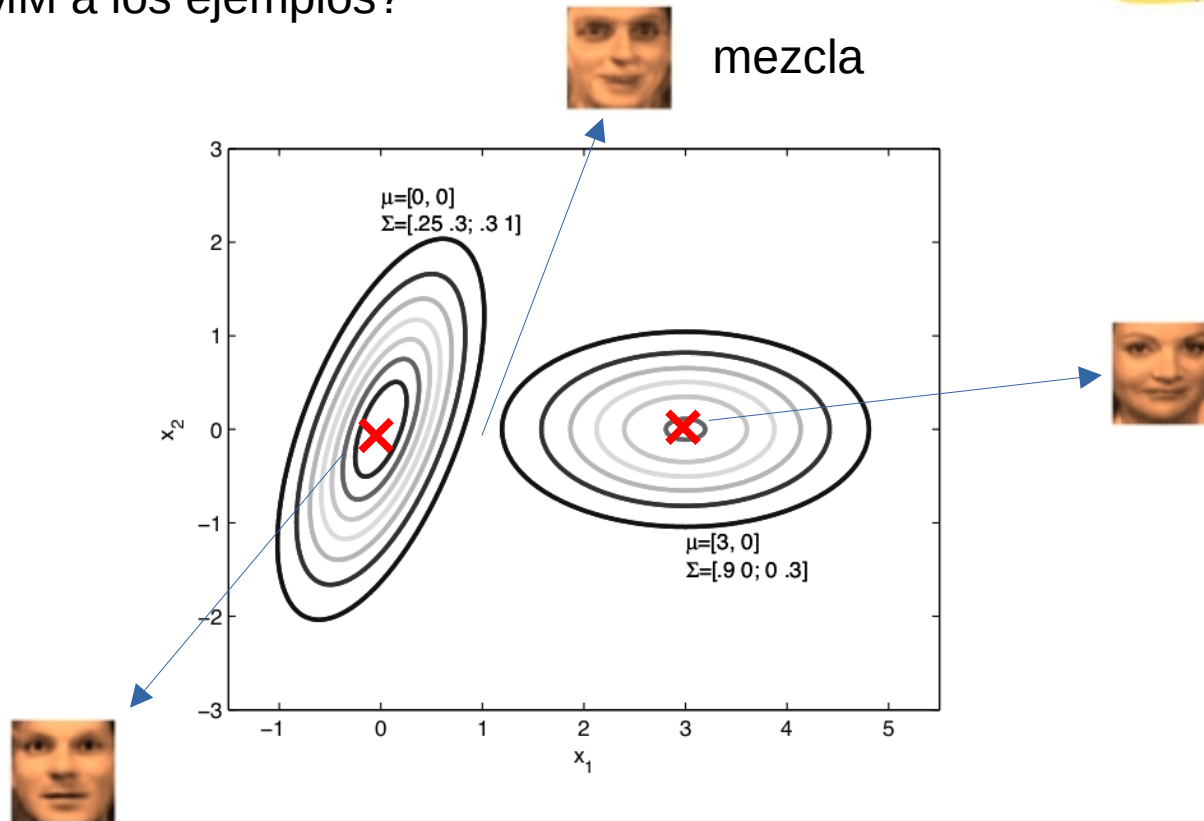
Si tengo 400 ejemplos ¿Cuántas Gaussianas pueden aproximar sin pérdida el dataset?

Cierre de la clase 6 – Actividad formativa

Si tengo dos datos ¿Cómo aproxima GMM a los ejemplos?



Dato: ✗



- Asociaciones -

Asociación

$$\{\text{Diapers}\} \longrightarrow \{\text{Beer}\}.$$

- Indica que si ocurre el antecedente, es probable que ocurra el consecuente.
- Usualmente involucran variables categóricas nominales.
- Se consolidan en reglas, las cuales usan {} para indicar asociaciones entre conjuntos denominados **itemsets**.
- En el ejemplo, ambos conjuntos son de cardinalidad 1.
- La asociación entre dos variables es un primer paso hacia la causalidad ya que define una relación de antecedente y consecuente.
- La diferencia con causalidad es que el antecedente es la causa y el consecuente es el efecto. Existe una relación lógica entre ambos que explica la observación.
- La asociación no necesariamente implica causa y efecto.

Reglas de Asociación

Datos:

<i>TID</i>	Items
1	{Bread, Milk}
2	{Bread, Diapers, Beer, Eggs}
3	{Milk, Diapers, Beer, Cola}
4	{Bread, Milk, Diapers, Beer}
5	{Bread, Milk, Diapers, Cola}

Regla: {Diapers} \longrightarrow {Beer}



Representación:

TID	Bread	Milk	Diapers	Beer	Eggs	Cola
1	1	1	0	0	0	0
2	1	0	1	1	1	0
3	0	1	1	1	0	1
4	1	1	1	1	0	0
5	1	1	1	0	0	1

Reglas de Asociación



Datos:

TID	Items
1	{Bread, Milk}
2	{Bread, Diapers, Beer, Eggs}
3	{Milk, Diapers, Beer, Cola}
4	{Bread, Milk, Diapers, Beer}
5	{Bread, Milk, Diapers, Cola}

Regla: {Diapers} \longrightarrow {Beer}



Representación:

TID	Bread	Milk	Diapers	Beer	Eggs	Cola
1	1	1	0	0	0	0
2	1	0	1	1	1	0
3	0	1	1	1	0	1
4	1	1	1	1	0	0
5	1	1	1	0	0	1

Items: $I = \{i_1, i_2, \dots, i_d\}$; transacciones: $T = \{t_1, t_2, \dots, t_N\}$

Soporte de un ítemset:

$$\sigma(X) = |\{t_i | X \subseteq t_i, t_i \in T\}|$$



En cuántas transacciones ocurre X



Reglas de Asociación

Una regla de asociación es una implicancia $X \longrightarrow Y$ tal que $X \cap Y = \emptyset$.

Se definen:

$$\text{Support, } s(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{N};$$

$$\text{Confidence, } c(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)}.$$

transacciones




Reglas de Asociación

Una regla de asociación es una implicancia $X \longrightarrow Y$ tal que $X \cap Y = \emptyset$.

Se definen:

$$\text{Support, } s(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{N};$$
$$\text{Confidence, } c(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)}.$$

transacciones 

Estrategia para generación de reglas:

1. Búsqueda de ítemsets frecuentes.
2. Generación de reglas candidatas a partir de ítemsets frecuentes.

Buscar asociaciones puede ser muy ineficiente. La eficiencia de la búsqueda es un tema crítico en reglas de asociación.

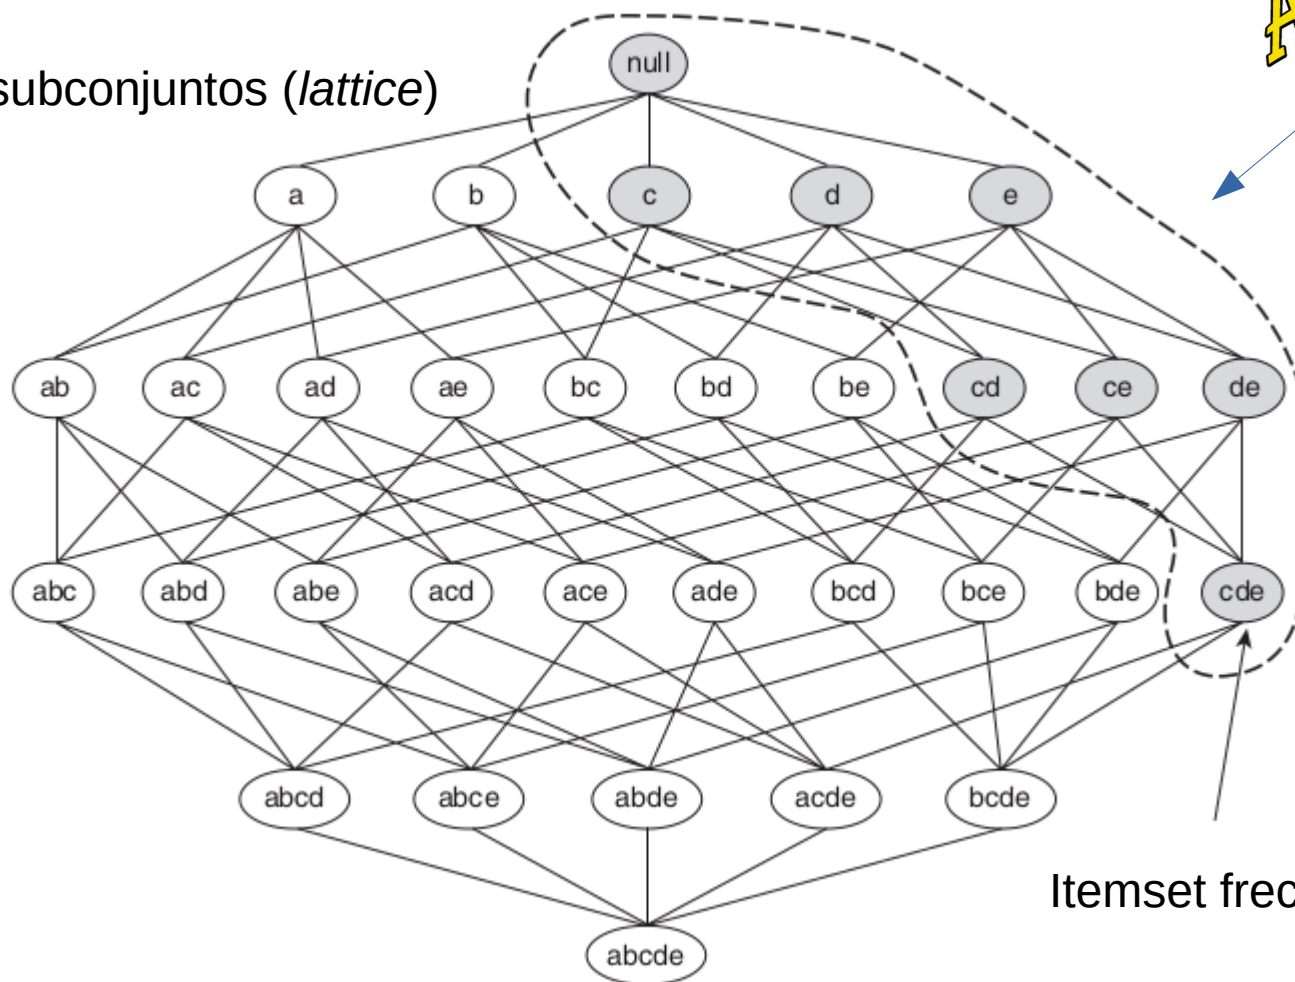
Principio Apriori

Si un ítemset es frecuente, todos sus subconjuntos son frecuentes.

Reglas de Asociación

Principio Apriori:

Estructura de subconjuntos (*lattice*)



Atención
Atención

Itemset frecuente



Reglas de Asociación



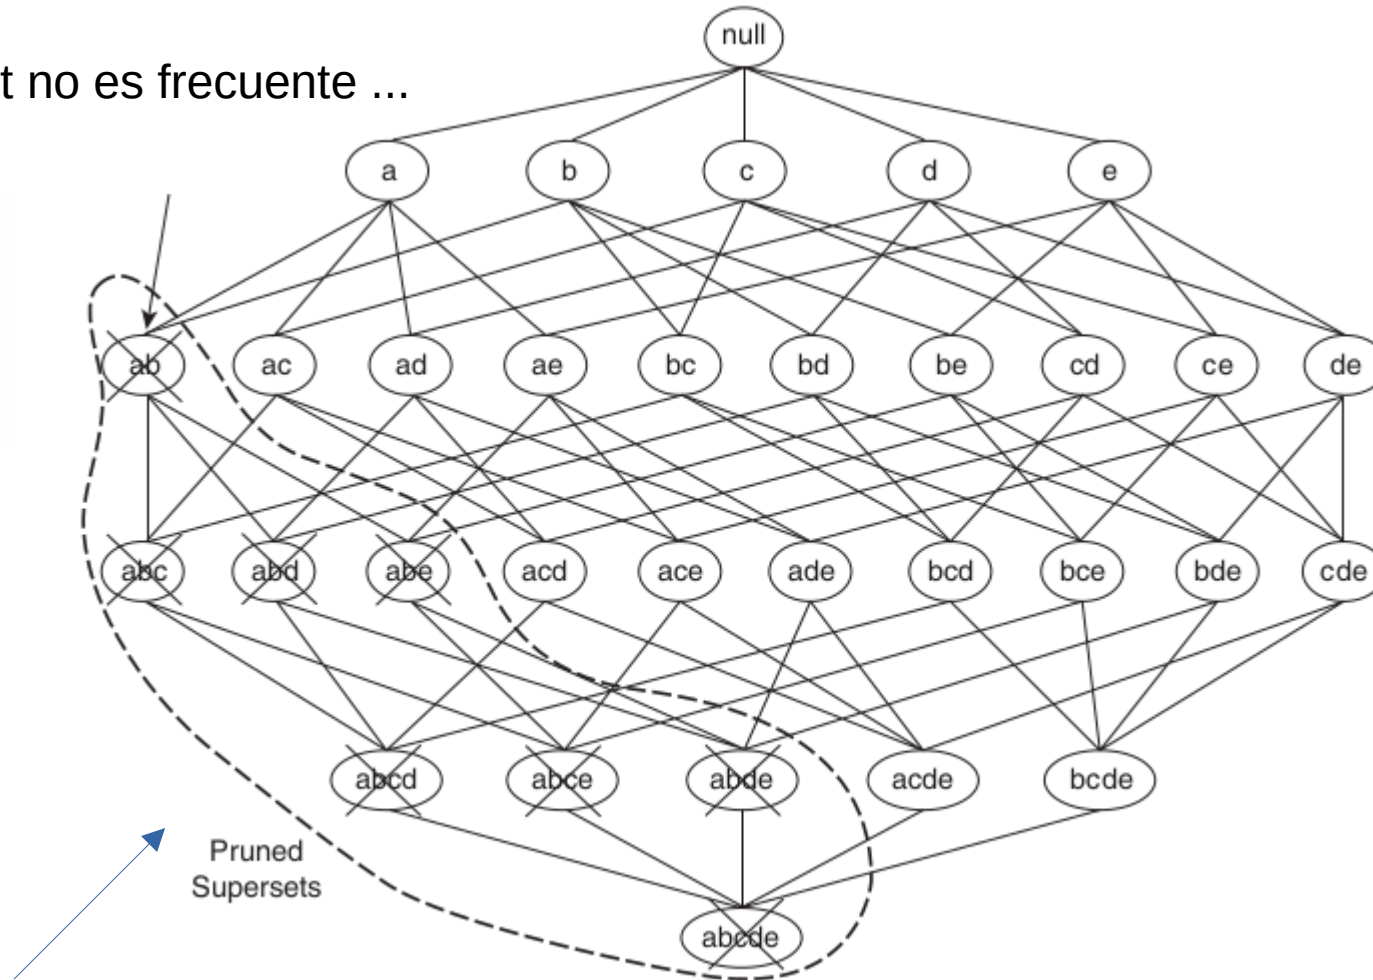

Principio de monotonicidad: $\forall X, Y \in J : (X \subseteq Y) \longrightarrow f(Y) \leq f(X),$

Reglas de Asociación



Principio de monotonicidad: $\forall X, Y \in J : (X \subseteq Y) \longrightarrow f(Y) \leq f(X),$

Si este itemset no es frecuente ...




... estos tampoco son frecuentes.

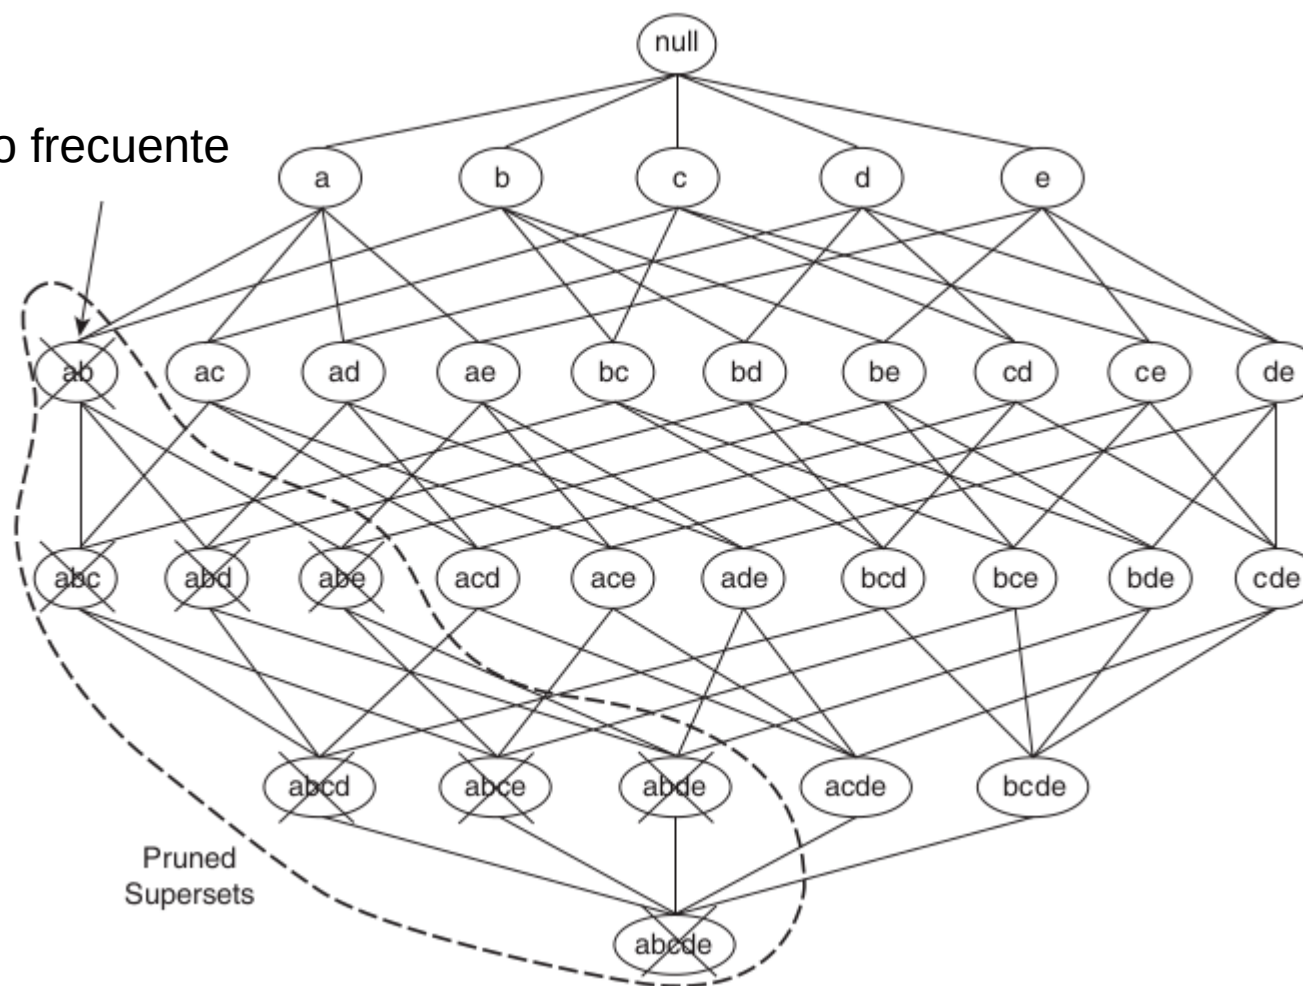
Reglas de Asociación

Principio de monotonidad: $\forall X, Y \in J : (X \subseteq Y) \longrightarrow f(Y) \leq f(X),$

Itemset no frecuente

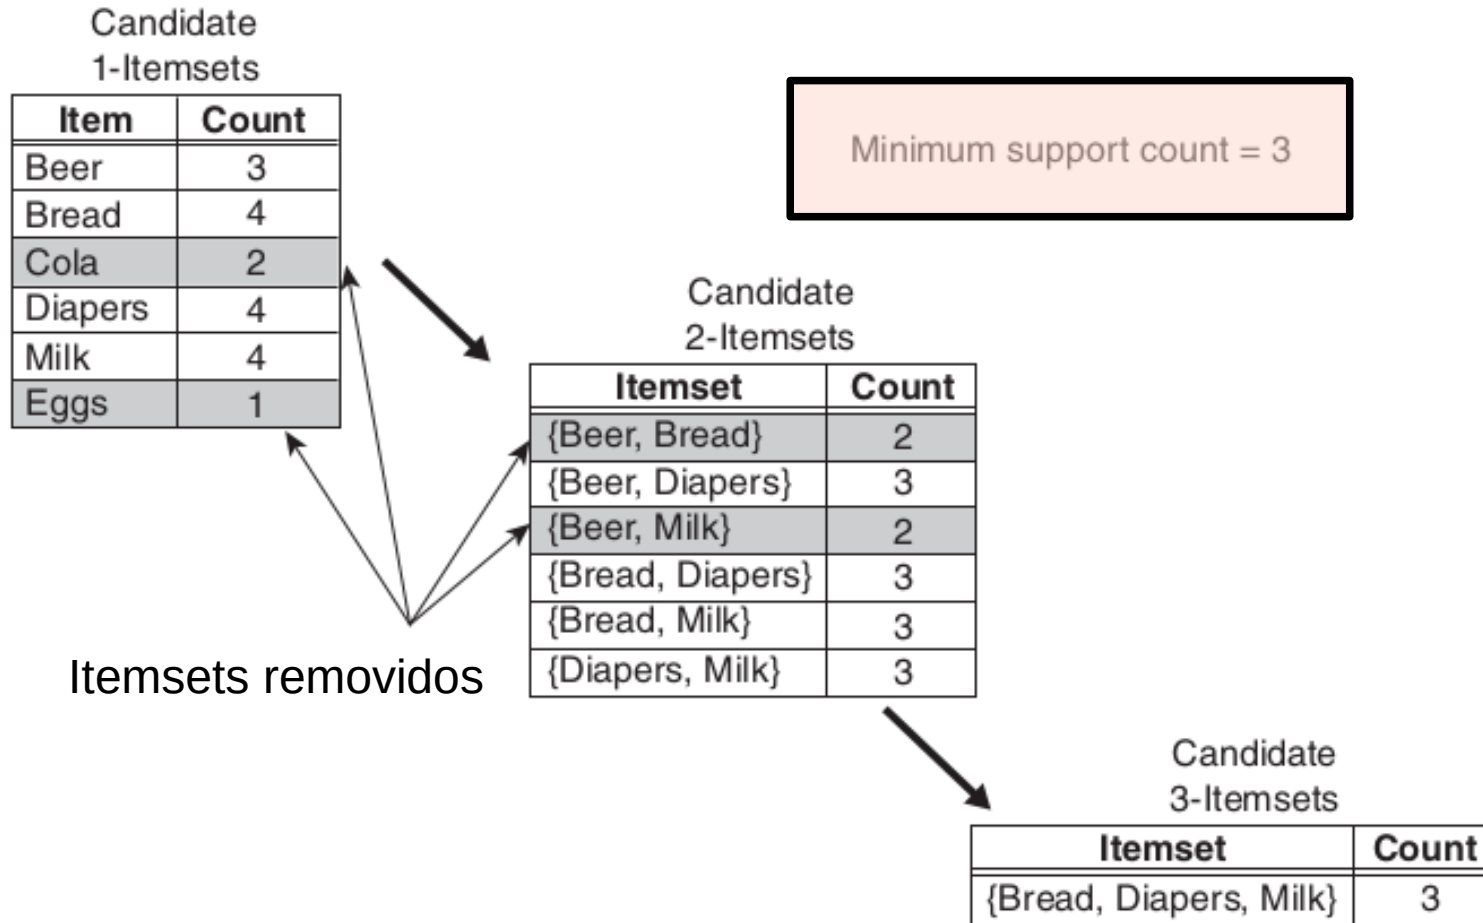


Podemos podar



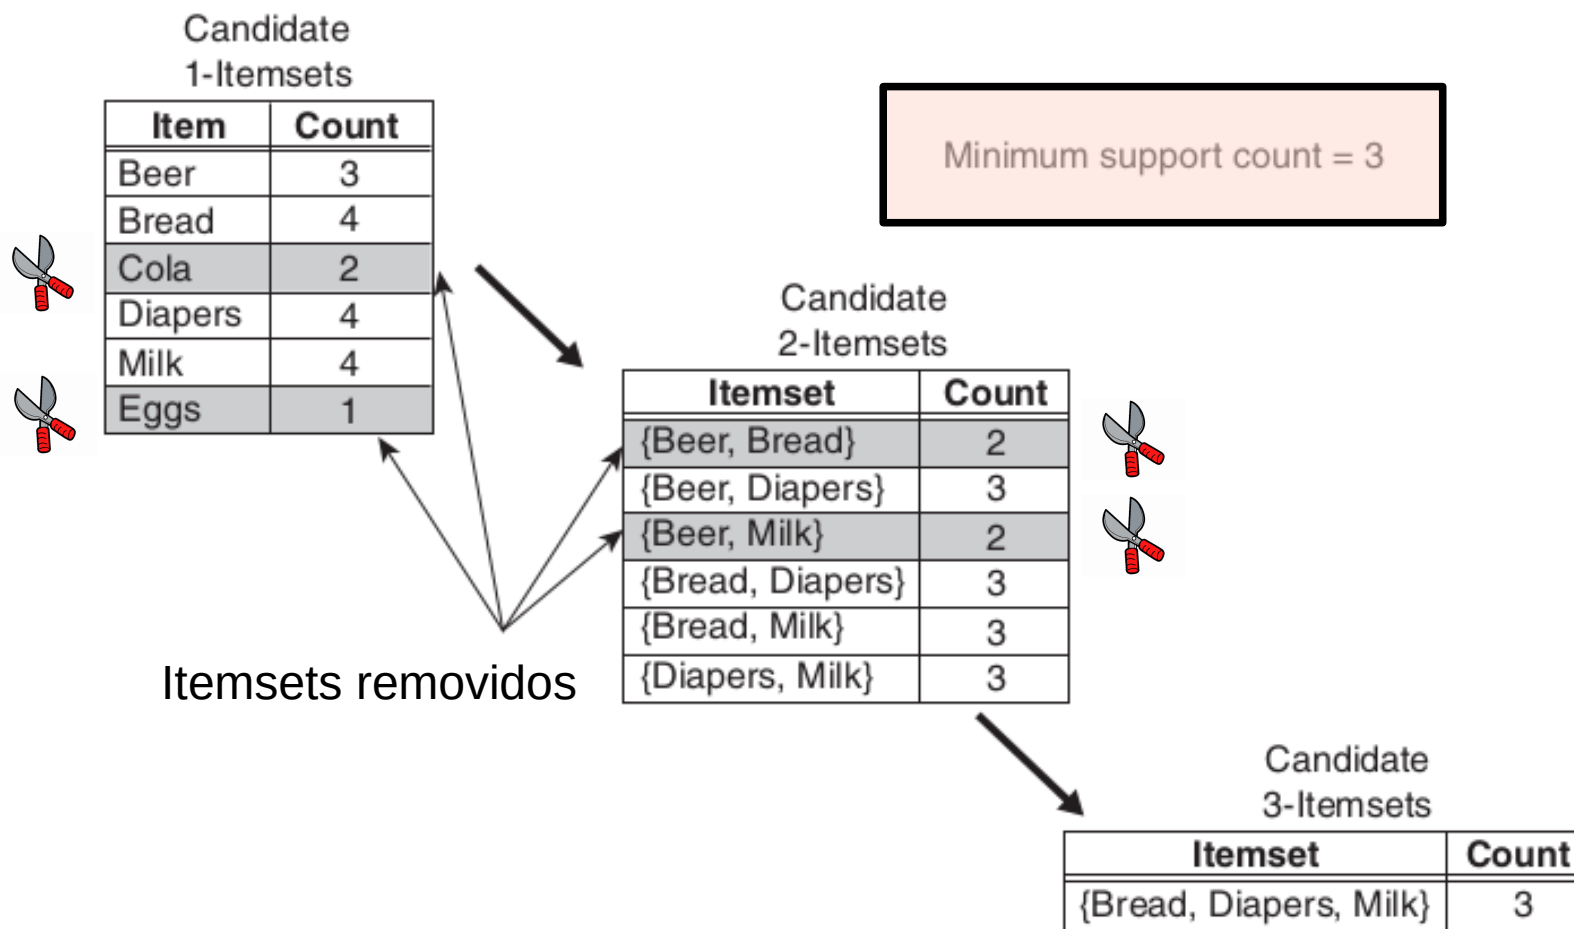
Reglas de Asociación

Uso algorítmico del principio de monotonidad: Buscamos por orden creciente de cardinalidad:



Reglas de Asociación

Uso algorítmico del principio de monotonidad: Buscamos por orden creciente de cardinalidad:





Reglas de Asociación

Ahora vamos a generar reglas a partir de itemset frecuentes.

Recordar:

$$\text{Support, } s(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{N};$$
$$\text{Confidence, } c(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)}.$$

Atención
Atención

Si una regla $X \longrightarrow Y - X$ no satisface un umbral de confianza, entonces toda regla de la forma $X' \longrightarrow Y - X'$, donde $\tilde{X} \subseteq X$, no puede satisfacer el umbral de confianza.



Reglas de Asociación

Ahora vamos a generar reglas a partir de itemset frecuentes.

Recordar:

$$\text{Support, } s(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{N};$$
$$\text{Confidence, } c(X \longrightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)}.$$

Atención
Atención



Si una regla $X \longrightarrow Y - X$ no satisface un umbral de confianza, entonces toda regla de la forma $X' \longrightarrow Y - X'$, donde $\tilde{X} \subseteq X$, no puede satisfacer el umbral de confianza.

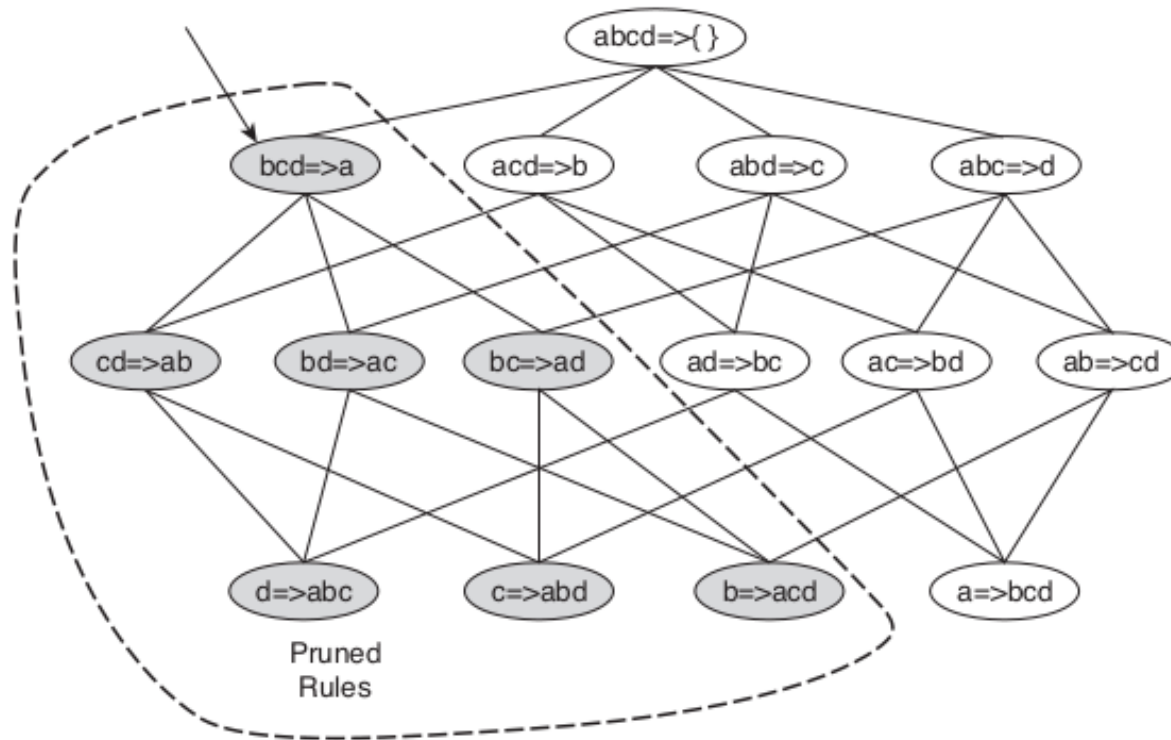
Principio de monotonía: $\forall X, Y \in J: (X \subseteq Y) \longrightarrow f(Y) \leq f(X),$

Dado que $\tilde{X} \subseteq X$, $\sigma(X) \leq \sigma(X')$, luego $\frac{\sigma(X \cup Y)}{\sigma(X)} \geq \frac{\sigma(X \cup Y)}{\sigma(X')}.$

Reglas de Asociación

Si una regla $X \rightarrow Y - X$ no satisface un umbral de confianza, entonces toda regla de la forma $X' \rightarrow Y - X'$, donde $\tilde{X} \subseteq X$, no puede satisfacer el umbral de confianza.

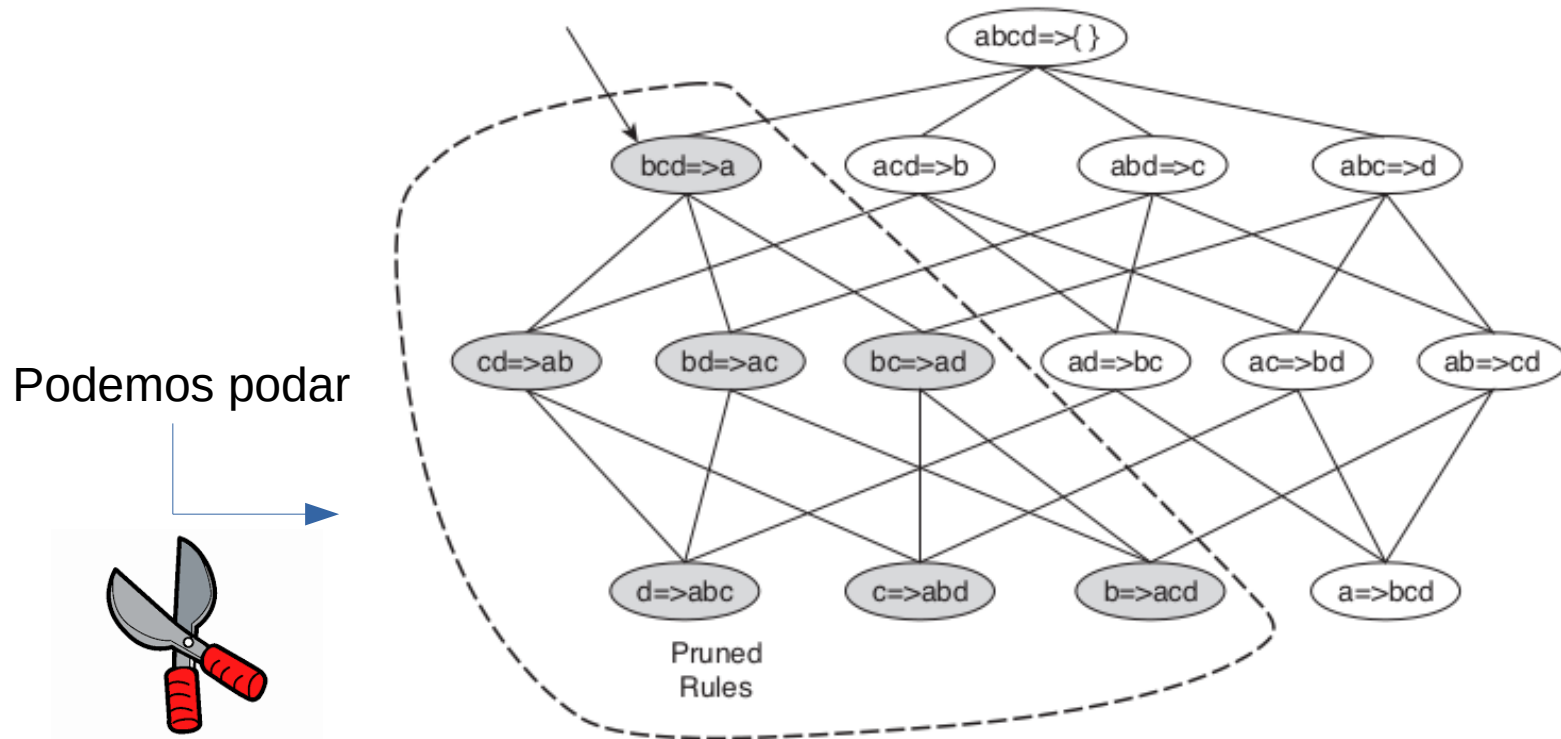
Regla de baja confianza



Reglas de Asociación

Si una regla $X \rightarrow Y - X$ no satisface un umbral de confianza, entonces toda regla de la forma $X' \rightarrow Y - X'$, donde $\tilde{X} \subseteq X$, no puede satisfacer el umbral de confianza.

Regla de baja confianza




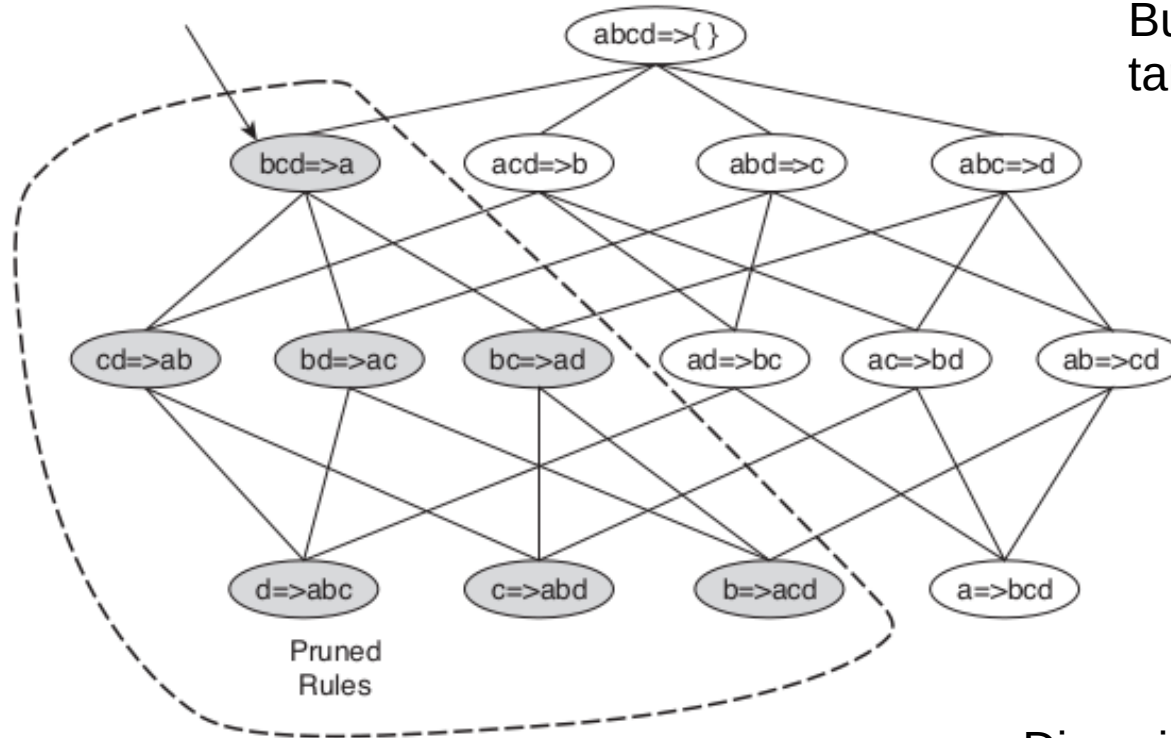
Reglas de Asociación

Si una regla $X \rightarrow Y - X$ no satisface un umbral de confianza, entonces toda regla de la forma $X' \rightarrow Y - X'$, donde $\tilde{X} \subseteq X$, no puede satisfacer el umbral de confianza.

Regla de baja confianza

Buscar aumentando el tamaño del consecuente

Podemos podar



Dirección de búsqueda

- ANEXO -

Reglas de Asociación

Para $k = 2$ no necesitamos algoritmo

Algorithm Rule generation of the *Apriori* algorithm.

```
1: for each frequent  $k$ -itemset  $f_k$ ,  $k \geq 2$  do
2:    $H_1 = \{i \mid i \in f_k\}$  {1-item consequents of the rule.}
3:   call ap-genrules( $f_k, H_1$ .)
4: end for
```

Algorithm Procedure ap-genrules(f_k, H_m).

```
1:  $k = |f_k|$  {size of frequent itemset.}
2:  $m = |H_m|$  {size of rule consequent.}
3: if  $k > m + 1$  then
4:    $H_{m+1} = \text{apriori-gen}(H_m)$ .
5:   for each  $h_{m+1} \in H_{m+1}$  do
6:      $\text{conf} = \sigma(f_k) / \sigma(f_k - h_{m+1})$ .
7:     if  $\text{conf} \geq \text{minconf}$  then
8:       output the rule  $(f_k - h_{m+1}) \rightarrow h_{m+1}$ .
9:     else
10:      delete  $h_{m+1}$  from  $H_{m+1}$ .
11:    end if
12:  end for
13:  call ap-genrules( $f_k, H_{m+1}$ .)
14: end if
```

El antecedente tendrá al menos un ítem
Aumento el consecuente en 1

$$\frac{\sigma(X \cup Y)}{\sigma(X)}$$

Una vez terminamos la verificación,
continuamos recursivamente.

Termina cuando H_{m+1} es vacío.