IIC 2433 Minería de Datos

https://github.com/marcelomendoza/IIC2433

Cierre de la clase 7 – Asociaciones

Asociaciones:

¿Cuál es la diferencia entre soporte y confianza de una regla?

¿Qué es lo que hace que una regla sea interesante? ¿Cómo ayuda en esto el lift?

Algoritmo Apriori:

¿Qué indica el principio de mononicidad?

¿Cómo lo aplicamos a la búsqueda de itemsets frecuentes?

¿Cómo lo aplicamos a la búsqueda de reglas interesantes?

Cierre de la clase 7 – Actividad formativa

¿Cómo encontramos reglas interesantes?

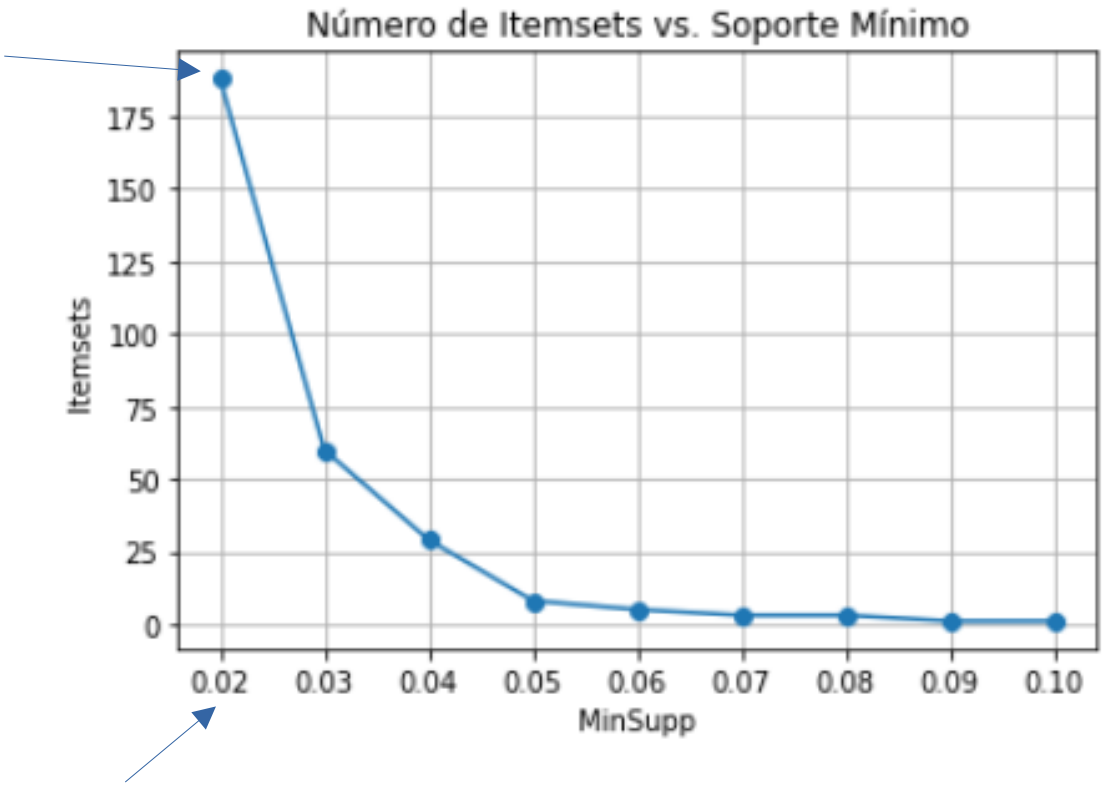

Para encontrar reglas interesantes es necesario **identificar un conjunto amplio de itemsets frecuentes** donde buscar.

Luego, en ese conjunto, aplicamos una condición de confianza alta, por ejemplo, confianza > 0.5.

Cierre de la clase 7 – Actividad formativa

¿Cómo encontramos reglas interesantes?

Para encontrar reglas interesantes es necesario **identificar un conjunto amplio de itemsets frecuentes** donde buscar.

Luego, en ese conjunto, aplicamos una condición de confianza alta, por ejemplo, confianza > 0.5.

```
itemsets = apriori(df, min_support = 0.02, use_colnames = True, verbose = 1)
```

```
Processing 705 combinations | Sampling itemset size 3 2
```

```
df_ar = association_rules(itemsets, metric = "confidence", min_threshold = 0.6)
df_ar[['antecedents','consequents','support','confidence']]
```

	antecedents	consequents	support	confidence
0	(22356)	(20724)	0.02162	0.676048
1	(21231)	(21232)	0.02264	0.740353
2	(21733)	(85123A)	0.02486	0.697140
3	(22386)	(85099B)	0.02860	0.633304
4	(22699)	(22697)	0.02080	0.724739
5	(22697)	(22699)	0.02080	0.756364
6	(85099F)	(85099B)	0.02378	0.643050

- Redes Bayesianas -

Un modelo basado en dependencias entre variables

Repaso de conceptos: Distribución conjunta

<u>Enfoque de Bayes</u>: Modelos para variable categórica/ordinal.

- Intelligence (I) ← 2
  - i^0 (low), i^1 (high),
- Difficulty (D) ← 2
  - d^0 (easy), d^1 (hard)
- Grade (G) ← 3
  - g^1 (A), g^2 (B), g^3 (C)

parametros
$2 \cdot 2 \cdot 3 = 12$

independent params
11

P(I,D,G)

I	D	G	Prob.
i^0	d^0	g^1	0.126
i^0	d^0	g^2	0.168
i^0	d^0	g^3	0.126
i^0	d^1	g^1	0.009
i^0	d^1	g^2	0.045
i^0	d^1	g^3	0.126
i^1	d^0	g^1	0.252
i^1	d^0	g^2	0.0224
i^1	d^0	g^3	0.0056
i^1	d^1	g^1	0.06
i^1	d^1	g^2	0.036
i^1	d^1	g^3	0.024

1

Repaso de conceptos: Probabilidad condicional

condition on g^1

I	D	G	Prob.
i^0	d^0	g^1	0.126
~~i^0~~	~~d^0~~	~~g^2~~	~~0.168~~
~~i^0~~	~~d^0~~	~~g^3~~	~~0.126~~
i^0	d^1	g^1	0.009
~~i^0~~	~~d^1~~	~~g^2~~	~~0.045~~
~~i^0~~	~~d^1~~	~~g^3~~	~~0.126~~
i^1	d^0	g^1	0.252
~~i^1~~	~~d^0~~	~~g^2~~	~~0.0224~~
~~i^1~~	~~d^0~~	~~g^3~~	~~0.0056~~
i^1	d^1	g^1	0.06
~~i^1~~	~~d^1~~	~~g^2~~	~~0.036~~
~~i^1~~	~~d^1~~	~~g^3~~	~~0.024~~

Condicionar es fijar una variable a un valor conocido (observación).

Repaso de conceptos: Marginalización de variable

Marginalizar es calcular la distribución (debe sumar 1) de una variable sobre la base de todos los posibles valores de las otras.

Marginalize I

P(I, D)

I	D	Prob.
i^0	d^0	0.282
i^0	d^1	0.02
i^1	d^0	0.564
i^1	d^1	0.134

D	Prob.
d^0	0.846
d^1	0.154

Repaso de conceptos: Distribución de probabilidad condicional

Supongamos que G tiene tres valores posibles (A, B y C).
Si la fila representa el condicionante, debe sumar 1.

I	D	G	Prob.
i^0	d^0	g^1	0.126
i^0	d^0	g^2	0.168
i^0	d^0	g^3	0.126

= 0.42

0.126 / 0.42

$P(G \mid I,D)$

	g^1	g^2	g^3
i^0,d^0	0.3	0.4	0.3
i^0,d^1	0.05	0.25	0.7
i^1,d^0	0.9	0.08	0.02
i^1,d^1	0.5	0.3	0.2

condicionante

A B C

Red Bayesiana

Una red Bayesiana es un modelo que representa las relaciones de dependencia entre variables categóricas. Modela la **distribución conjunta** sobre la base de dependencias (condicionantes).

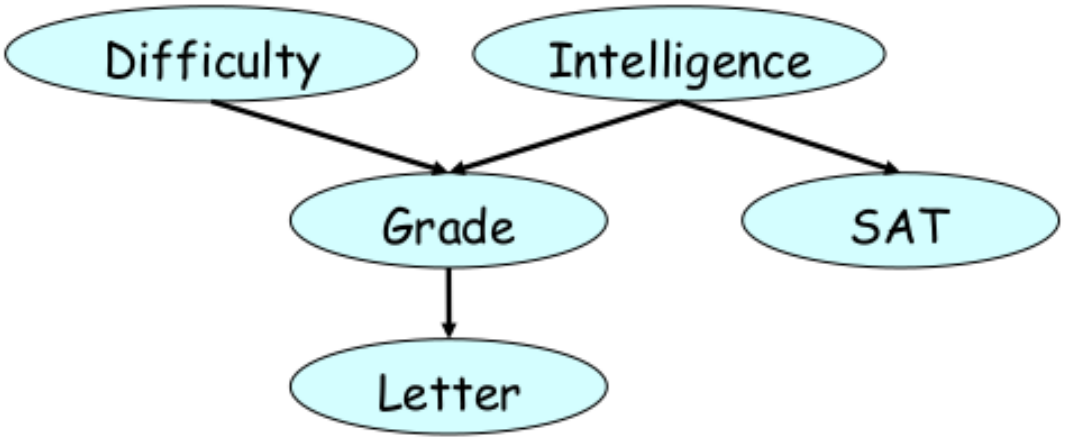

Red Bayesiana

La red incluirá las probabilidades condicionales.

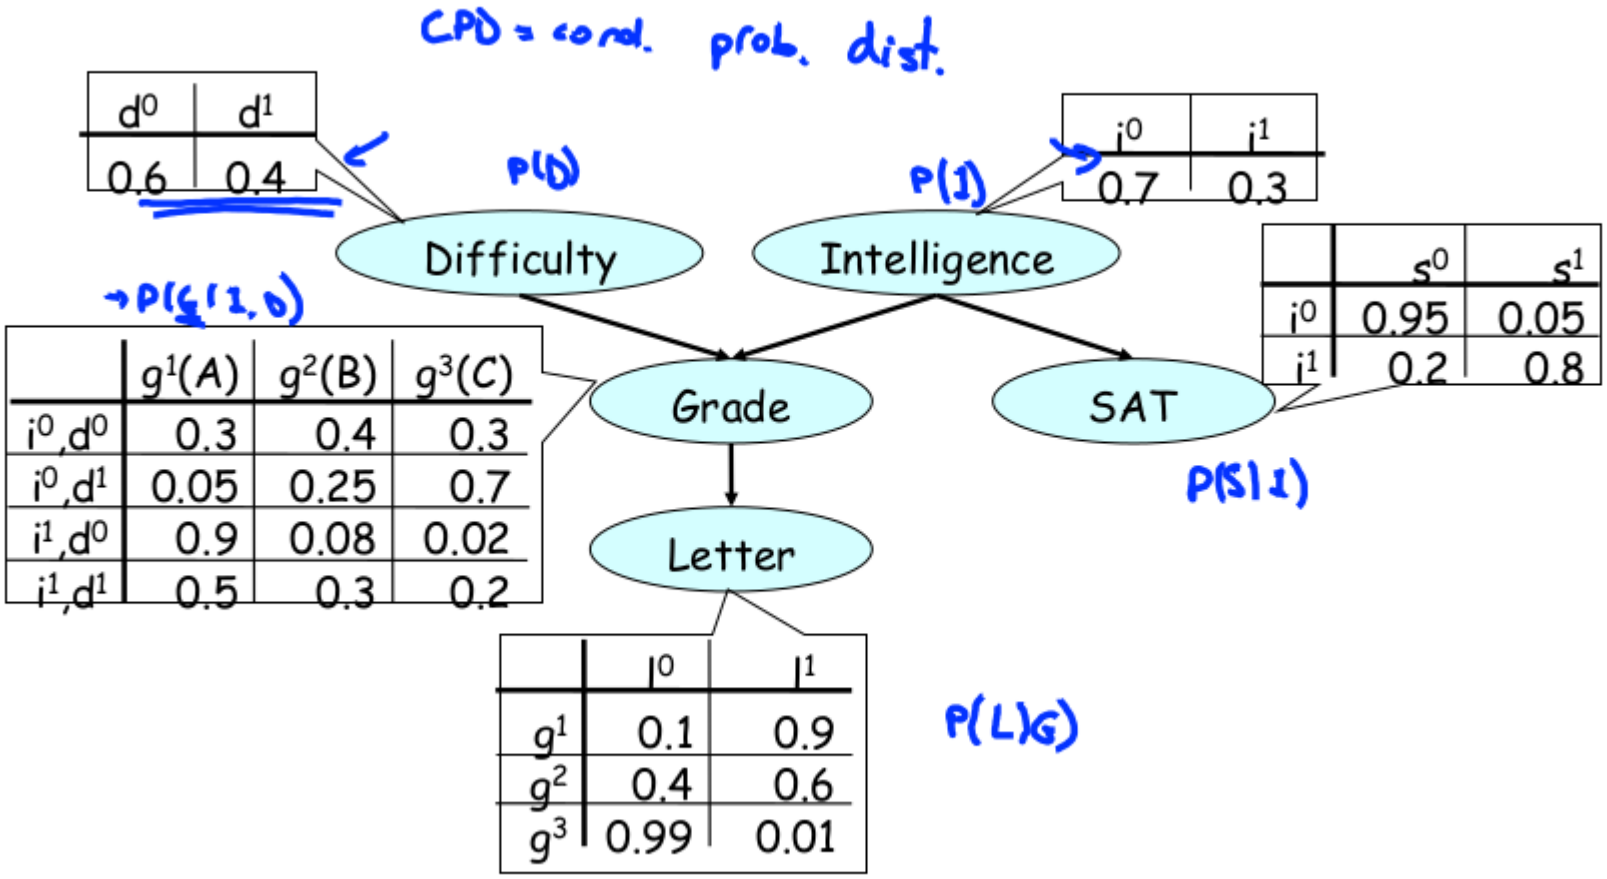

d^0	d^1
0.6	0.4

i^0	i^1
0.7	0.3

	$g^1(A)$	$g^2(B)$	$g^3(C)$
i^0,d^0	0.3	0.4	0.3
i^0,d^1	0.05	0.25	0.7
i^1,d^0	0.9	0.08	0.02
i^1,d^1	0.5	0.3	0.2

	s^0	s^1
i^0	0.95	0.05
i^1	0.2	0.8

	l^0	l^1
g^1	0.1	0.9
g^2	0.4	0.6
g^3	0.99	0.01

Red Bayesiana

Finalmente el modelo es una representación gráfica de la distribución conjunta.

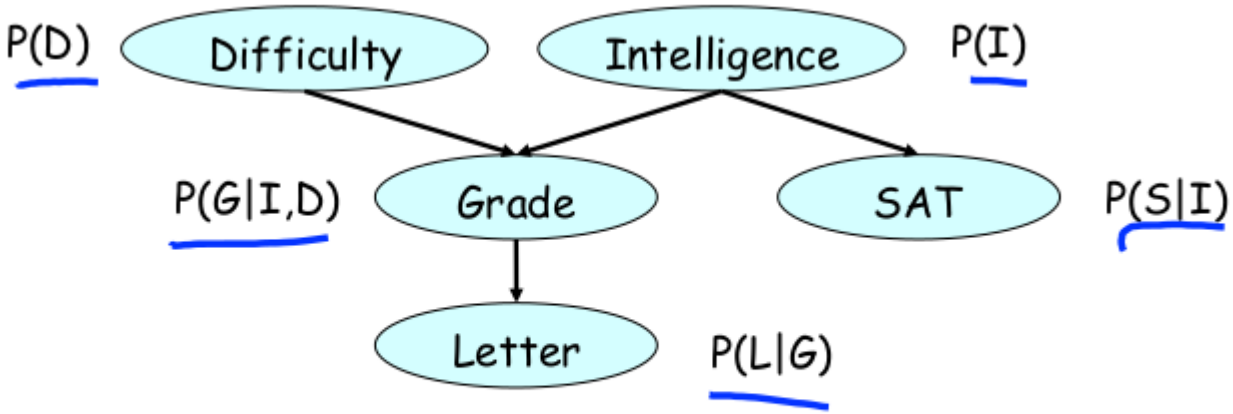

$$P(D,I,G,S,L) = P(D)\,P(I)\,P(G|I,D)\,P(S|I)\,P(L|G)$$

Cada CPD corresponde a un factor de la red.

Red Bayesiana

El modelo es útil para razonamiento basado en evidencia.
Si la calificación es C ¿Cuánto de esto se explica porque el curso es difícil?

$P(d^1) = 0.4$

$P(d^1 \mid g^3) \approx 0.63$ ← ?

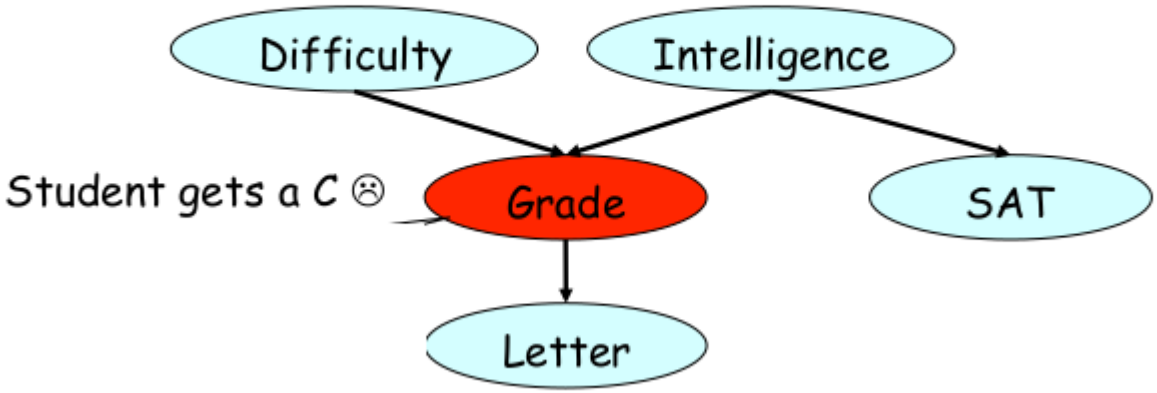

¿Cómo puedo saber P(d|g) dado g si la red va en dirección contraria?

Red Bayesiana

¿Cómo puedo saber P(d|g) dado g si la red va en dirección contraria?

Inferencia: $P(d^1 \mid g^3)$

Regla de Bayes:

$$P(d^1 \mid g^3) = \frac{P(g^3 \mid d^1) \cdot P(d^1)}{P(g^3)}$$

Necesitamos $P(g^3 \mid d^1)$ — Grade depende de D e I, por lo tanto marginalizamos sobre I:

$$P(g^3 \mid d^1) = \sum_{i \in \{i^0, i^1\}} P(g^3 \mid i, d^1) \cdot P(i)$$

Sustituyendo con valores de la CPD $P(G \mid D, I)$ y el prior $P(I)$:

	$g^1(A)$	$g^2(B)$	$g^3(C)$
i^0, d^0	0.3	0.4	0.3
i^0, d^1	0.05	0.25	0.7
i^1, d^0	0.9	0.08	0.02
i^1, d^1	0.5	0.3	0.2

$$= \underbrace{P(g^3 \mid i^0, d^1)}_{0.7} \cdot \underbrace{P(i^0)}_{0.7} + \underbrace{P(g^3 \mid i^1, d^1)}_{0.2} \cdot \underbrace{P(i^1)}_{0.3}$$

i^0	i^1
0.7	0.3

$$= 0.7 \times 0.7 + 0.2 \times 0.3 = 0.49 + 0.06 = \mathbf{0.55}$$

Red Bayesiana

¿Cómo puedo saber P(d|g) dado g si la red va en dirección contraria?

$$P(d^1 \mid g^3) = \frac{P(g^3 \mid d^1) \cdot P(d^1)}{P(g^3)}$$

Marginalizamos g^3:

d^0	d^1
0.6	0.4

$$P(g^3) = \sum_d \sum_i P(g^3 \mid d, i) \cdot P(d) \cdot P(i)$$

i^0	i^1
0.7	0.3

(d, i)	$P(g^3 \mid d, i)$	$P(d)$	$P(i)$	producto
d^0, i^0	0.30	0.6	0.7	$0.30 \times 0.6 \times 0.7 = 0.1260$
d^1, i^0	0.70	0.4	0.7	$0.70 \times 0.4 \times 0.7 = 0.1960$
d^0, i^1	0.02	0.6	0.3	$0.02 \times 0.6 \times 0.3 = 0.0036$
d^1, i^1	0.20	0.4	0.3	$0.20 \times 0.4 \times 0.3 = 0.0240$
			Total	**0.3496**

	$g^1(A)$	$g^2(B)$	$g^3(C)$
i^0, d^0	0.3	0.4	0.3
i^0, d^1	0.05	0.25	0.7
i^1, d^0	0.9	0.08	0.02
i^1, d^1	0.5	0.3	0.2

Red Bayesiana

¿Cómo puedo saber P(d|g) dado g si la red va en dirección contraria?

Finalmente:

Valores calculados en pasos anteriores:

$P(g^3 \mid d^1) = 0.55 \quad \leftarrow \quad$ marginalización sobre I

$P(d^1) = 0.4 \quad \leftarrow \quad$ prior (dado)

$P(g^3) = 0.3496 \quad \leftarrow \quad$ marginalización sobre D e I

Sustituyendo:

$$P(d^1 \mid g^3) = \frac{\overbrace{0.55}^{P(g^3|d^1)} \times \overbrace{0.4}^{P(d^1)}}{\underbrace{0.3496}_{P(g^3)}} = \frac{0.22}{0.3496} \approx \mathbf{0.63}$$

Prior $P(d^1) = 0.4 \quad \longrightarrow \quad$ Posterior $P(d^1 \mid g^3) \approx 0.63$

Aprendizaje estructural de la red

Si ajustamos una red Bayesiana desde datos, no sabremos apriori las dependencias entre las variables. Necesitamos entonces seleccionar modelos en base a las posibles relaciones de dependencia:

Buscaremos según:

- Búsqueda exhaustiva.
- Heurística de búsqueda (Hill climbing).

Seleccionamos la red según un criterio.

Selección de modelos con BIC

El Bayesian Information Criterion (BIC) permite seleccionar modelos de redes Bayesianas. Se calcula según:

$$BIC = k \ln(n) - 2 \ln(MLE)$$

datos

parámetros (filas de las condicionales)

Mientras más cerca estemos del 0, mejor.