

IIC 2433 Minería de Datos

<https://github.com/marcelomendoza/IIC2433>

Cierre de la clase 8 – Dependencias entre variables



Dependencias:

¿Cuál es la diferencia entre asociación y dependencia?

Redes Bayesianas:

¿Qué representan las relaciones en una red Bayesiana?

¿Qué representa la red Bayesiana?

¿Qué es un razonamiento basado en evidencia?

Cierre de la clase 8 – Actividad formativa

¿Qué representan estas relaciones?

(A \perp F, E, G, D)
(B \perp F, E, D, G, H | C, A)
(C \perp F, E, D, G, H | A)
(D \perp F, C, A, B, H | G)
(E \perp F, C, A, B, H | G, D)
(F \perp C, E, D, G, A, B)
(G \perp F, C, A, B, H)
(H \perp C, E, D, G, B | F, A)

- Causalidad -

Dependencia no es lo mismo que causalidad

La escala de la causalidad



Rung	Action	Question
Association (1)	<i>Observing</i>	How does observing X change my belief in Y?
Intervention (2)	<i>Doing</i>	What will happen to Y if I do X?
Counterfactual (3)	<i>Imagining</i>	If I had done X, what would Y be?

¿Qué entendemos por independencia entre variables?

$$P(Y) = P(Y|X)$$

$$P(X) = P(X|Y)$$

La probabilidad marginal de Y es igual a la probabilidad condicional de Y|X. Análogamente, la probabilidad marginal de X es igual a la probabilidad condicional de X|Y.

Una consecuencia importante de independencia es que su distribución conjunta es el producto de las marginales:

$$P(X, Y) = P(X)P(Y)$$

Usaremos como notación de independencia:

$$X \perp\!\!\!\perp Y$$

¿Qué entendemos por independencia condicional entre variables?

$$P(X, Y|Z) = P(X|Z)P(Y|Z)$$

X e Y son condicionalmente independientes en relación con Z si su distribución conjunta, dado Z, es el producto de las condicionales X|Z e Y|Z.

La notación será:

$$X \perp\!\!\!\perp Y|Z$$

Distinguiremos además entre independencia en el modelo (grafo) y en la distribución conjunta:

$$X \perp\!\!\!\perp_p Y$$

$$X \perp\!\!\!\perp_G Y$$

Independencia en G

Dos variables X e Y serán independientes en G si no existe un camino que las conecte directa o indirectamente.

Dos variables X e Y serán condicionalmente independientes en G dado Z cuando Z **bloquee** todos los caminos entre X e Y .


Condiciones para inferencia causal

Necesitamos asegurar que podemos mapear las independencias condicionales de G a independencias estadísticas (p). Para esto se necesita la condición causal de Markov, la cual indica que toda variable debe ser independiente de sus no descendientes si conozco a sus padres:


$$V_i \perp\!\!\!\perp_G V_j \mid PA(V_i) \quad \forall_{j \neq i \in G(V, E) \setminus \{DE(V_i), PA(V_i)\}}$$

Condición causal de Markov

La clave está en si la variable es observada o no



V_i y V_j son dependientes porque tienen una causa común




... esperamos que V_i y V_j se vuelvan **independientes**


Condición causal de Markov

La clave está en si la variable es observada o no

Si controlamos $PA(V_i)$...



V_i y V_j son dependientes porque la información fluye desde V_j a V_i pasando por $PA(V_i)$



... esperamos que V_i y V_j se vuelvan independientes

Condición causal de Markov

La condición causal de Markov es relevante ya que:

$$X \perp\!\!\!\perp_G Y|Z \Rightarrow X \perp\!\!\!\perp_P Y|Z$$

Observemos que el reverso no es necesariamente cierto:

$$X \perp\!\!\!\perp_P Y|Z \Rightarrow X \perp\!\!\!\perp_G Y|Z$$




¿Por qué? Al testear independencia condicional sobre la base de una muestra finita, se introduce un error de estimación.

Estructuras frecuentes en modelos causales


Cadenas:

$$A \perp\!\!\!\perp_G C | B$$



Forks:


$$A \perp\!\!\!\perp C | B$$



Estructuras frecuentes en modelos causales

Colliders (estructuras v):

$$A \perp\!\!\!\perp C$$



Sin embargo:

$$A \not\perp\!\!\!\perp C|B$$



d -separación



Diremos que dos variables en G están d -separadas si todos los caminos entre ellas están bloqueados.

¿Cuándo se bloquea un camino entre dos variables?

Se bloquea el camino cuando hay un collider en el camino entre ellas y no podemos controlar el consecuente o si hay un fork o cadena que contiene una variable en el medio que podemos controlar.

Variables que podemos controlar:



Condiciones para bloqueo entre i y k :

- Existen $i \leftarrow j \rightarrow k$ o bien $i \rightarrow j \rightarrow k$ tal que $j \in \mathcal{I}$
- o bien existe $i \rightarrow j \leftarrow k$ tal que $j \notin \mathcal{I}$


La d es de direccional.

d -separación

... *entendiendo el concepto*



¿Cuáles variables debería controlar para que X e Y sean d -separables?




d -separación

... *entendiendo el concepto*



¿Cuáles variables debiera controlar para que X e Y sean d -separables?



R.: **A**