IIC 2433 Minería de Datos

https://github.com/marcelomendoza/IIC2433

Cierre de la clase 8 – Dependencias entre variables

Dependencias:

¿Cuál es la diferencia entre asociación y dependencia?

Redes Bayesianas:

¿Qué representan las relaciones en una red Bayesiana?

¿Qué representa la red Bayesiana?

¿Qué es un razonamiento basado en evidencia?

Cierre de la clase 8 – Actividad formativa

¿Qué representan estas relaciones?

```
(A ⊥ F, E, G, D)
(B ⊥ F, E, D, G, H | C, A)
(C ⊥ F, E, D, G, H | A)
(D ⊥ F, C, A, B, H | G)
(E ⊥ F, C, A, B, H | G, D)
(F ⊥ C, E, D, G, A, B)
(G ⊥ F, C, A, B, H)
(H ⊥ C, E, D, G, B | F, A)
```

- Causalidad -

Dependencia no es lo mismo que causalidad

La escala de la causalidad

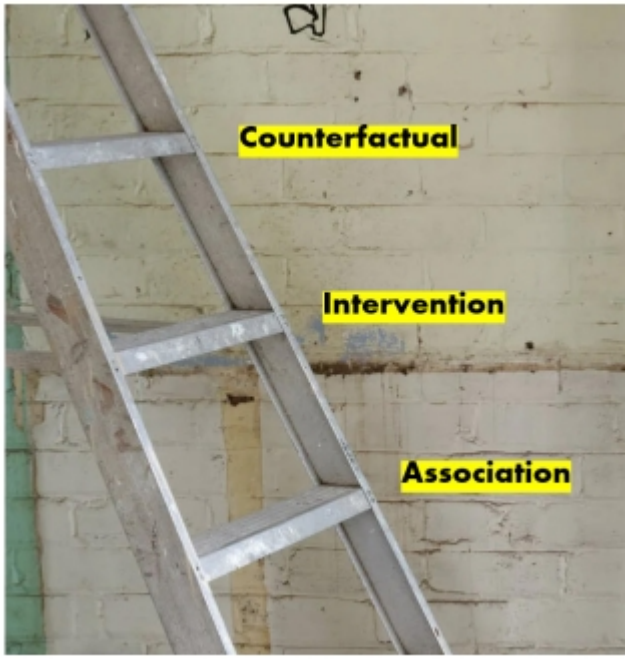

Rung	Action	Question
Association (1)	*Observing*	How does observing X change my belief in Y?
Intervention (2)	*Doing*	What will happen to Y if I do X?
Counterfactual (3)	*Imagining*	If I had done X, what would Y be?

¿Qué entendemos por independencia entre variables?

$$P(Y) = P(Y|X)$$

$$P(X) = P(X|Y)$$

La probabilidad marginal de Y es igual a la probabilidad condicional de Y|X. Análogamente, la probabilidad marginal de X es igual a la probabilidad condicional de X|Y.

Una consecuencia importante de independencia es que su distribución conjunta es el producto de las marginales:

$$P(X, Y) = P(X)P(Y)$$

Usaremos como notación de independencia:

$$X \perp\!\!\!\perp Y$$

¿Qué entendemos por independencia condicional entre variables?

$$P(X, Y|Z) = P(X|Z)P(Y|Z)$$

X e Y son condicionalmente independientes en relación con Z si su distribución conjunta, dado Z, es el producto de las condicionales X|Z e Y|Z.

La notación será:

$$X \perp\!\!\!\perp Y|Z$$

Distinguiremos además entre independencia en el modelo (grafo) y en la distribución conjunta:

$$X \perp\!\!\!\perp_{\mathrm{P}} Y \qquad\qquad X \perp\!\!\!\perp_{\mathrm{G}} Y$$

Independencia en G

Dos variables X e Y serán independientes en G si no existe un camino que las conecte directa o indirectamente.

Dos variables X e Y serán condicionalmente independientes en G dado Z cuando Z bloquee todos los caminos entre X e Y.

Condiciones para inferencia causal

Necesitamos asegurar que podemos mapear las independencias condicionales de G a independencias estadísticas (p). Para esto se necesita la condición causal de Markov, la cual indica que **toda variable debe ser independiente de sus no descendientes si <u>controlo (intervengo)</u> a sus padres**:

$$V_i \perp\!\!\!\perp_G V_j \,\Big|\, PA(V_i)\ \forall_{j \neq i \in G(V,E) \setminus \{DE(V_i), PA(V_i)\}}$$

Condición causal de Markov

La clave está en si la variable es **controlada** o no

Si controlamos la causa PA(V*i*)...

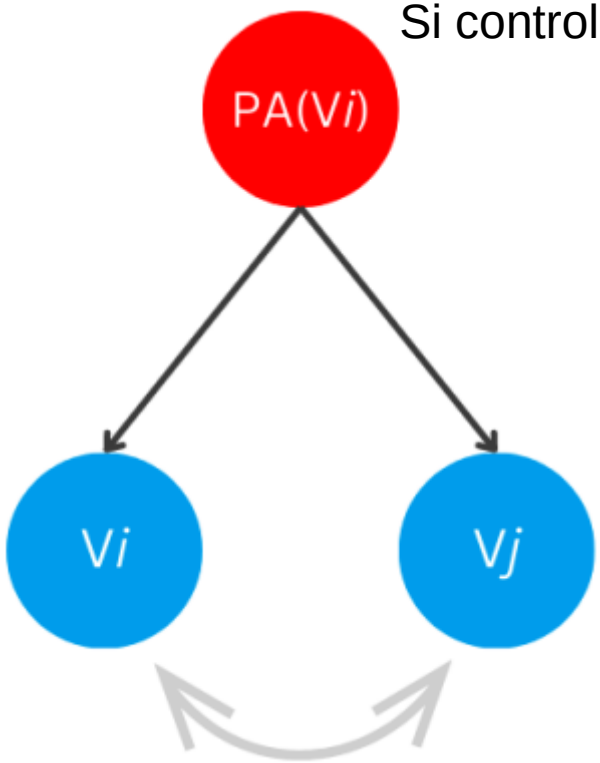

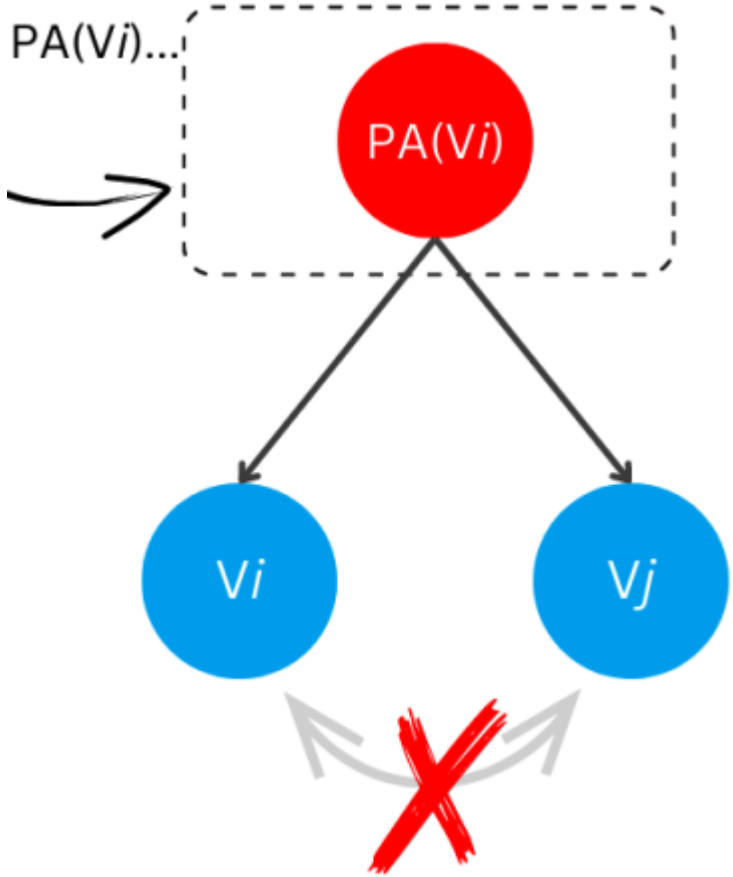

Vi y Vj son dependientes porque tienen una causa común

… esperamos que Vi y Vj se vuelvan **independientes**

Condición causal de Markov

La clave está en si la variable es **controlada** o no

Si controlamos PA(V*i*)...

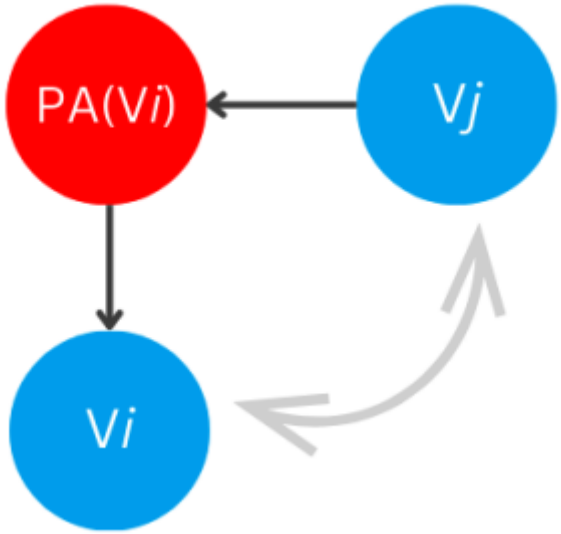

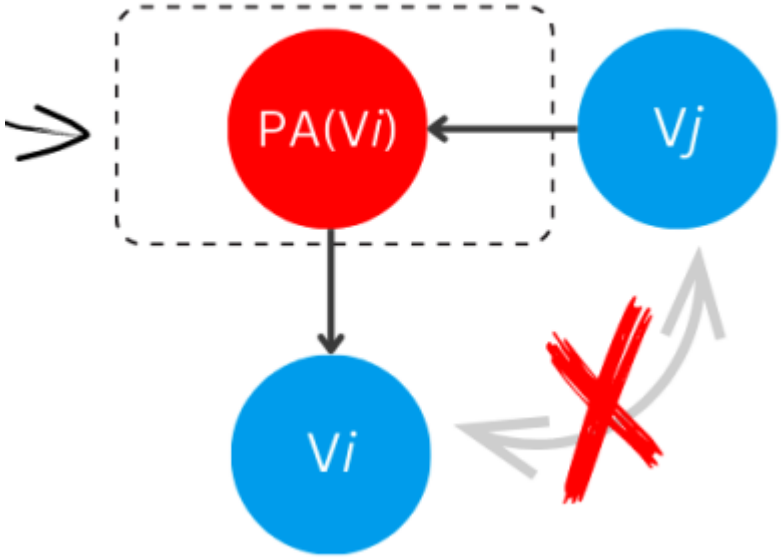

Vi y Vj son dependientes porque la información fluye desde Vj a Vi pasando por PA(Vi)

… esperamos que Vi y Vj se vuelvan independientes

Condición causal de Markov

La condición causal de Markov es relevante ya que:

$$X \perp\!\!\!\perp_{G} Y \mid Z \Rightarrow X \perp\!\!\!\perp_{P} Y \mid Z$$

Observemos que el reverso no es necesariamente cierto:

$$X \perp\!\!\!\perp_{P} Y \mid Z \Rightarrow X \perp\!\!\!\perp_{G} Y \mid Z$$

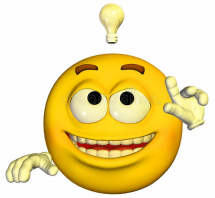

¿Por qué? Al testear independencia condicional sobre la base de una muestra finita (modelo), se introduce un error de estimación.

Estructuras frecuentes en modelos causales

Cadenas: $A \perp\!\!\!\perp_G C | B$

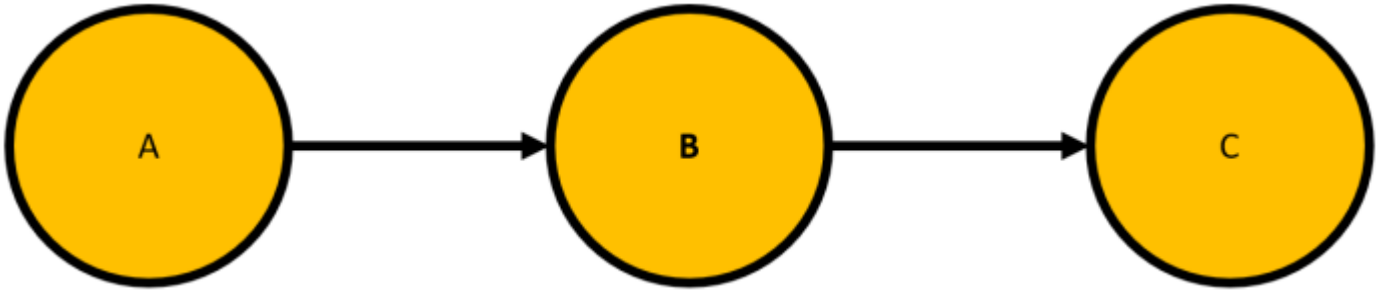

Forks: $A \perp\!\!\!\perp_G C | B$

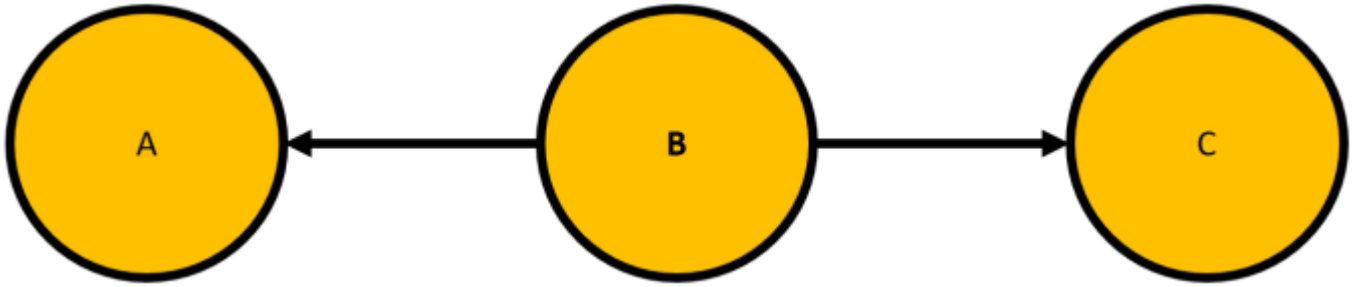

Estructuras frecuentes en modelos causales

Colliders (estructuras v): $A \perp\!\!\!\perp_G C$

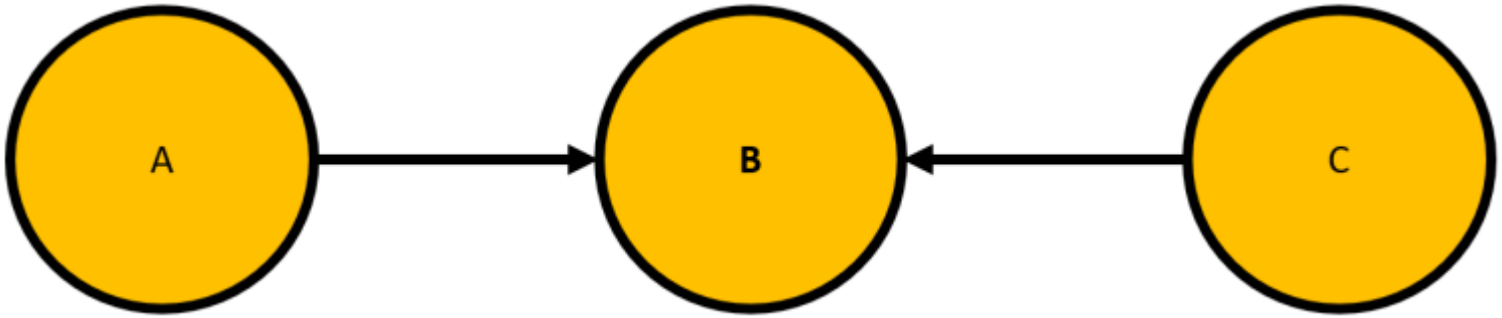

Sin embargo: $A \not\perp\!\!\!\perp_G C | B$

d-separación

Diremos que dos variables en G están *d*-separadas si todos los caminos entre ellas están bloqueados.

¿Cuándo se bloquea un camino entre dos variables?

Se bloquea el camino cuando hay un **collider** en el camino entre ellas y **no podemos controlar** el consecuente o si hay un **fork** o **cadena** que contiene una variable en el medio que podemos **controlar**.

Variables que podemos controlar: $\mathcal{Z}$

Condiciones para bloqueo entre *i* y *k*:

- Existen $i \leftarrow j \rightarrow k$ o bien $i \rightarrow j \rightarrow k$ tal que $j \in \mathcal{Z}$
- o bien existe $i \rightarrow j \leftarrow k$ tal que $j \notin \mathcal{Z}$

La *d* es de direccional.

d-separación

… entendiendo el concepto

¿Cuáles variables debiera **controlar** para que X e Y sean *d*-separables?

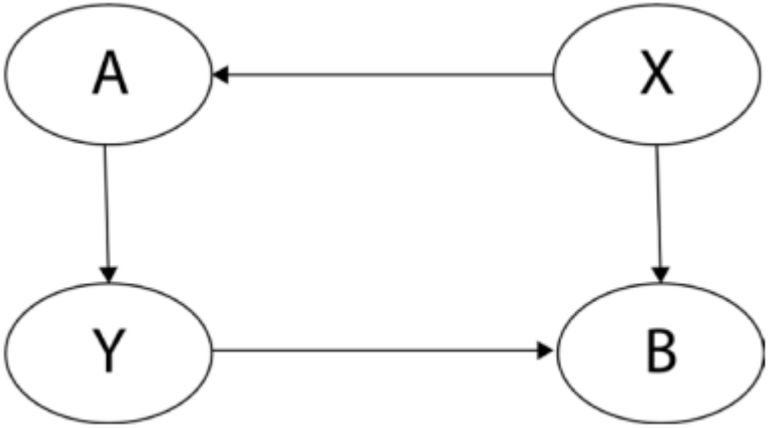

d-separación

… entendiendo el concepto

¿Cuáles variables debiera **controlar** para que X e Y sean *d*-separables?

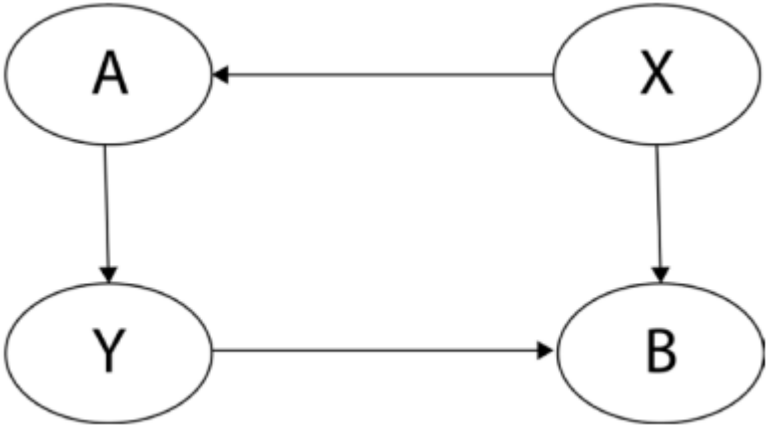

R.: **A**

Intervenir se representa con el operador **do:**

$$P(Y, B, X \mid do(A = a)) = P(X) \cdot P(Y \mid A = a) \cdot P(B \mid X, Y)$$

Diferencia entre Red Bayesiana y Modelo Causal

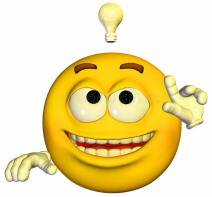

Red Causal (SCM / DAG)

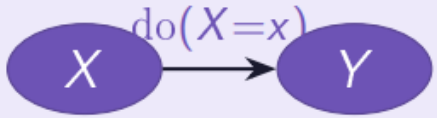

$Y = f(X, U)$ — *mecanismo generativo*

Aristas	mecanismo causal
Consulta clave	$P(Y \mid \mathrm{do}(X{=}x))$
Inversion aristas	× cambia el modelo
Contrafactuales	✓ nivel 3 de Pearl
Intervencion	✓ operador $\mathrm{do}(\cdot)$ nativo

Red Bayesiana (BN)

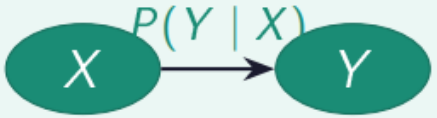

$P(X, Y) = P(X) \cdot P(Y \mid X)$
— *factorizacion*

Aristas	dependencia estadistica
Consulta clave	$P(Y \mid X{=}x)$
Inversion aristas	✓ Markov-equivalente
Contrafactuales	× no representables
Intervencion	× no modelable