



IIC 2433 Minería de Datos

<https://github.com/marcelomendoza/IIC2433>

Cierre de la clase 10 – Intervenciones



Intervenciones:

Si queremos hacer un deconfounding ¿Qué es lo que debemos hacer?

¿Cuál es la diferencia entre estimación y estimando?

Front-door y back-door:


¿Qué establece el criterio back-door?

¿Qué es una variable mediadora?

¿Qué establece el criterio front-door?

Cierre de la clase 10 – Intervenciones

	X	Z	Y
0	4.112216	-2.145154	-0.416641
1	5.033208	-3.557968	-1.715015
2	2.072369	-0.980547	-0.156815
3	4.945853	-2.637407	-0.785717
4	6.507559	-3.719618	-1.959987
...	...	...	...
995	5.246228	-3.577730	-1.520773
996	6.546688	-4.235398	-1.465884
997	9.374855	-5.489424	-3.496549
998	9.176765	-4.474747	-2.941831
999	4.637124	-3.840523	-1.651353



Sólo front-door obtiene una expresión para el estimando

```
### Estimand : 1  
Estimand name: backdoor  
No such variable(s) found!
```

```
### Estimand : 2  
Estimand name: iv  
No such variable(s) found!
```

```
### Estimand : 3  
Estimand name: frontdoor  
Estimand expression:  

$$E \left[ \frac{d}{d[Z]}(Y) \cdot \frac{d}{d[X]}([Z]) \right]$$

```

Cierre de la clase 10 – Intervenciones

	X	Z1	Z2	Y
0	5.205841	0.244745	0.236655	0.812072
1	0.624142	1.050330	-0.599829	0.148622
2	7.295969	-0.527297	-0.091966	1.012046
3	3.802128	-0.328517	-0.569314	1.272041
4	2.384882	-0.364086	-0.572526	0.502528
...	...	...	...	...
995	9.861890	-2.081233	0.469809	0.645653
996	2.837282	0.815817	-0.406366	0.281442
997	4.261860	-0.055185	-0.268553	1.364996
998	5.739891	-2.075536	0.325745	0.737930
999	3.535107	-0.601190	1.153480	2.512154

Estimand type: EstimandType.NONPARAM

Estimand : 1
Estimand name: backdoor
No such variable(s) found!

Estimand : 2
Estimand name: iv
No such variable(s) found!


Estimand : 3
Estimand name: frontdoor
Estimand expression:

$$E \left[\frac{d}{d[Z_2, Z_1]}(Y) \cdot \frac{\partial}{\partial [X]}([Z_2, Z_1]) \right]$$

Estimand assumption 1, Full-mediation: Z2,Z1 intercepts (blocks) all directed paths from X to Y.

Estimand assumption 2, First-stage-unconfoundedness: If $U \rightarrow \{X\}$ and $U \rightarrow \{Z_2, Z_1\}$ then $P(Z_2, Z_1 | X, U) = P(Z_2, Z_1 | U)$

Estimand assumption 3, Second-stage-unconfoundedness: If $U \rightarrow \{Z_2, Z_1\}$ and $U \rightarrow Y$ then $P(Y | Z_2, Z_1, X, U) = P(Y | Z_2, Z_1, U)$



El criterio front-door
obtiene una expresión
para el estimando

Regresión lineal no va a funcionar aquí

- Refutación, matching, ATT y ATE -

Estimar para medir el efecto en la población

Refutación

- Nos faltan algunos elementos para completar esta revisión de causalidad. En esta clase los veremos. Estos son **refutación** y **estimadores**.
- Para validar modelos causales usaremos **bootstrap** y analizaremos la consistencia de los estimandos para cada setting.
- Al comparar los estimandos, estimaremos el **p-valor** de que ambos estimandos provengan de la misma distribución. Si los estimandos son similares, el p-valor será muy alto.

```
refute_subset = model.refute_estimate(  
    estimand=estimand,  
    estimate=estimate,  
    method_name="data_subset_refuter",  
    subset_fraction=0.4)
```

```
Refute: Use a subset of data  
Estimated effect:-0.4201729192182768  
New effect:-0.41971603098814647  
p value:0.98
```

← Ambos son similares, por lo que no podemos refutar el efecto causal

Estimadores

- Queremos observar efectos causales en una población de unidades observables. Esto tiene varios desafíos.
- Comenzaremos por matching. Matching es una familia de métodos para estimar efectos causales haciendo matching entre observaciones similares en los grupos de tratamiento y no tratamiento.
- Importante: Se requiere que la relación entre el tratamiento y la salida esté **deconfounded**, es decir, que **todos los confounders sean observables y que no se controlen colliders**.
- Vamos a comparar salida con y sin intervención y mediremos la diferencia entre ambos grupos:

The diagram shows the formula $\tau_i = Y_i^1 - Y_i^0$ enclosed in a black rectangular box. A blue arrow points from the text "Salida con intervención" to the Y_i^1 term. Another blue arrow points from the text "Salida sin intervención" to the Y_i^0 term.

$$\tau_i = Y_i^1 - Y_i^0$$

Salida con intervención

Salida sin intervención

Match exacto

Idea: Dado el problema de inferencia causal, queremos estimar el efecto de un tratamiento T en $\{0,1\}$ sobre la salida Y . El problema fundamental es que **nunca observamos ambos potenciales resultados para el mismo evento**.

Matching exacto resuelve esto comparando unidades tratadas con controles que tienen **exactamente las mismas características***.

Conjunto de matches exactos

Sea $X = (X_1, \dots, X_p)$ el vector de covariables pre-tratamiento. Para cada unidad tratada i :

$$\mathcal{M}(i) = \{j : T_j = 0, X_j = X_i\}$$

Luego podemos estimar el efecto causal individual:

Efecto causal individual

$$\hat{\tau}_i = Y_i - \frac{1}{|\mathcal{M}(i)|} \sum_{j \in \mathcal{M}(i)} Y_j$$

* en causalidad a las características se les llama covariables.


Match exacto

ATT: Se define el Average Treatment Effect on the Treated (ATT) vía matching exacto como el efecto promedio sobre la base de la comparación entre todas las unidades tratadas y para cada una de ellas, su conjunto de matches exactos.

Estimador ATT vía matching exacto

$$\hat{\tau}_{\text{ATT}} = \frac{1}{n_1} \sum_{i: T_i=1} \hat{\tau}_i = \frac{1}{n_1} \sum_{i: T_i=1} \left(Y_i - \frac{1}{|\mathcal{M}(i)|} \sum_{j \in \mathcal{M}(i)} Y_j \right)$$

Veamos que cada unidad puede tener una base de comparación distinta:



Match inexacto

Limitación: con covariables continuas o muchas covariables discretas, la probabilidad de encontrar matches exactos es muy baja.

Matching inexacto relaja la definición de conjunto de matches introduciendo una métrica de distancia:

Idea central

Reemplazar la condición $X_j = X_i$ por una métrica de distancia $d(\cdot, \cdot)$:

$$\mathcal{M}(i) = \{j : T_j = 0, d(X_i, X_j) \leq \delta\} \quad \text{o bien} \quad \mathcal{M}(i) = \arg \min_{j: T_j=0} d(X_i, X_j)$$

Dado que los controles son más o menos cercanos, la influencia de cada control en el estimador incluye un peso:

Estimador ATT con pesos

$$\hat{\tau}_{\text{ATT}} = \frac{1}{n_1} \sum_{i: T_i=1} \left(Y_i - \sum_{j \in \mathcal{M}(i)} w_{ij} Y_j \right)$$

donde w_{ij} son los pesos de los controles emparejados (e.g., $w_{ij} = 1/|\mathcal{M}(i)|$ para k -NN).

No toda la población es intervenida

Limitación: ATT basa la estimación de efecto causal sobre la base de observar el grupo intervenido e ir a buscar sujetos no intervenidos similares. Pero en esta estimación no se está considerando toda la población.

Average Treatment Effect on the Controls (ATC) mide el efecto causal promedio sobre los no intervenidos. Es lo mismo que ATT pero al revés, es decir, para un no intervenido buscamos su conjunto de match en los intervenidos.

Caso	Unidad i	Match $j(i)$	Contribución
ATT-component	$T_i = 1$	$j(i)$: no tratado	$Y_i(1) - Y_{j(i)}(0)$
ATC-component	$T_i = 0$	$j(i)$: tratado	$Y_{j(i)}(1) - Y_i(0)$

Si consideramos ambos casos, tenemos el Average Treatment Effect (ATE).

Average Treatment Effect (ATE)

Definición

Se define el **factor de signo orientado** como:

$$s_i = 2T_i - 1$$

Este factor codifica el grupo de pertenencia como un signo aritmético:

T_i	$2T_i$	$s_i = 2T_i - 1$	Interpretación
1	2	+1	unidad tratada $\Rightarrow$ signo positivo
0	0	-1	unidad control $\Rightarrow$ signo negativo

Caso 1: $T_i = 1$

$j(i)$ es un **control**

$$\begin{aligned}\hat{\delta}_i &= Y_i - Y_{j(i)} \\ &= \hat{Y}_i(1) - \hat{Y}_i(0)\end{aligned}$$

Caso 2: $T_i = 0$

$j(i)$ es un **tratado**

$$\begin{aligned}\hat{\delta}_i &= Y_{j(i)} - Y_i \\ &= \hat{Y}_i(1) - \hat{Y}_i(0)\end{aligned}$$

Average Treatment Effect (ATE)

Usando el factor de signo orientado verificamos cada caso:

Caso 1: $T_i = 1 \Rightarrow s_i = +1$

$$\begin{aligned} s_i \cdot (Y_i - Y_{j(i)}) &= (+1)(Y_i - Y_{j(i)}) = Y_i - Y_{j(i)} \\ &= \underbrace{Y_i}_{\hat{Y}_i(1)} - \underbrace{Y_{j(i)}}_{\hat{Y}_i(0)} \quad \checkmark \end{aligned}$$

Caso 2: $T_i = 0 \Rightarrow s_i = -1$

$$\begin{aligned} s_i \cdot (Y_i - Y_{j(i)}) &= (-1)(Y_i - Y_{j(i)}) = Y_{j(i)} - Y_i \\ &= \underbrace{Y_{j(i)}}_{\hat{Y}_i(1)} - \underbrace{Y_i}_{\hat{Y}_i(0)} \quad \checkmark \end{aligned}$$

Entonces el efecto individual para cualquier unidad de la población es:

Expresión compacta del efecto individual

$$\hat{\delta}_i = (2T_i - 1)(Y_i - Y_{j(i)})$$

válida para toda unidad i , sea tratada o control.

Estimador ATE

Unit	Treatment	Outcome
A	1	9
B	0	1.5

$N=2$, A y B pareados bajo match exacto

$$\hat{\tau}_{ATE} = \frac{1}{N} \sum_i (2T_i - 1)(Y_i - Y_{j(i)})$$

Unit A: $(2 \times 1 - 1)(9 - 1.5) = 1 \times 7.5 = 7.5$

Unit B: $(2 \times 0 - 1)(1.5 - 9) = -1 \times -7.5 = 7.5$

$$\hat{\tau}_{ATE} = \frac{1}{2} (7.5 + 7.5) = \frac{1}{2} \times 15 = 7.5$$

Estimador ATE

- Podemos relajar la definición del estimador ATE incluyendo matching inexacto.
- Para cada unidad i , recolectamos todos los $j(i)$ que satisfacen algún criterio a definir, y tomamos el promedio sobre ellas para hacer la comparación:

$$\hat{\tau}_{ATE} = \frac{1}{N} \sum_i \left(2 T_i - 1 \right) \left(Y_i - \left(\frac{1}{M} \sum_m Y_{j_m(i)} \right) \right)$$

- Ejemplo: Tres variables, **edad**, **toma un curso** de finanzas, y **ganancias** en la bolsa. Queremos saber si tomar el curso tiene un efecto causal en las ganancias de la persona. Toma el curso es booleano (toma/no toma).

	age	took_a_course	earnings
0	19	False	110579.0
1	28	False	142577.0
2	22	True	130520.0
3	25	True	142687.0
4	24	False	127832.0

Estimador ATE con match inexacto

- Vamos a agrupar por edad (criterio de pareo).

```
earnings_data.groupby(['age', 'took_a_course']).mean()
```

- Separamos en grupo de tratamiento (toma el curso) y grupo de control (no lo toma).

```
treatment_avg = earnings_data.query('took_a_course==1')['earnings'].mean()
cntrl_avg = earnings_data.query('took_a_course==0')['earnings'].mean()

treatment_avg - cntrl_avg
```

- Si medimos la diferencia directa desde los datos nos da 6695 USD, que sería la ganancia a favor de quienes cursan la asignatura.

Estimador ATE

- Hagamoslo con modelos causales.

1) Modelamos el SCM: Edad puede influir en ambas variables (fork):

```
nodes = ['took_a_course', 'earnings', 'age']
edges = [
    ('took_a_course', 'earnings'),
    ('age', 'took_a_course'),
    ('age', 'earnings')
]
```

...

```
model = CausalModel(
    data=earnings_data,
    treatment='took_a_course',
    outcome='earnings',
    graph=gml_string
)
```

Estimador ATE

2) Identificamos el efecto causal:

```
estimand = model.identify_effect()
```

```
### Estimand : 1
Estimand name: backdoor
Estimand expression:
      d
      ----- (E[earnings | age])
d[took_a_course]
Estimand assumption 1, Unconfoundedness: If  $U \rightarrow \{\text{took\_a\_course}\}$  and  $U \rightarrow \text{earnings}$  then  $P(\text{earnings} | \text{took\_a\_course}, \text{age}, U) = P(\text{earnings} | \text{took\_a\_course}, \text{age})$ 
```

Nos dice que el back-door es suficiente para estimar el efecto causal. Debemos controlar por edad.

Estimador ATE

3) Calculamos el estimando usando ATE con match inexacto:

```
estimate = model.estimate_effect(  
    identified_estimand=estimand,  
    method_name='backdoor.distance_matching',  
    target_units='ate',  
    method_params={'distance_metric': 'minkowski', 'p': 2})
```

Observemos que no hemos estandarizado el matching a edad.
Estamos usando una función de distancia.

El estimado es de 10464, mucho mayor que el mostrado al hacer la diferencia directa.

4) Refutamos:

```
refutation = model.refute_estimate(  
    estimand=estimand,  
    estimate=estimate,  
    method_name='data_subset_refuter',  
    subset_fraction=0.4)  
  
print(refutation)
```

Refute: Use a subset of data
Estimated effect:10464.5
New effect:10080.510625
p value:0.6

