



IIC 2433 Minería de Datos

<https://github.com/marcelomendoza/IIC2433>

Cierre de la clase 11 – Matching y efecto promedio



Matching:

En matching exacto ¿Cuál es la dificultad?


Efectos promedio:

¿Qué es ATT?

¿Qué es ATC?

Cierre de la clase 11 – Matching y efecto promedio

Estudiar el efecto de X en Y implica que X debe ser variable de intervención.



En este ejemplo, se debe controlar A:

```
### Estimand : 1
Estimand name: backdoor
Estimand expression:
d
——(E[Y|A])
d[X]
Estimand assumption 1, Unconfoundedness:
```

El efecto medible es: 2.58188197158841

Y rechazamos refutación:

```
Refute: Use a subset of data
Estimated effect:2.5818819715884103
New effect:2.4907166786966384
p value:0.62
```

- Matching, propensity scores y modelo de salida -

Modelar para medir el efecto de la intervención

Propensity scores

- Al usar match inexacto, se introduce un bias que depende del criterio usado para formar las unidades de comparación. Si tenemos muchas variables, hacer match sufrirá del efecto de la maldición de la dimensionalidad.
- Para abordar este problema, usaremos **propensity scores**, que es la probabilidad de recibir tratamiento condicionado a las variables observadas:

$$\hat{e}(X) = P(T = 1|X = x)$$

- En la definición X representa las covariables y T es la variable de tratamiento. Se estudia el efecto causal desde T hacia Y.

Propensity scores

- ¿Qué es la probabilidad de recibir tratamiento condicionado a las variables observadas?

En un estudio observacional nadie asigna el tratamiento al azar. Las unidades lo reciben en función de sus características. Entonces, la propensión a pertenecer al grupo experimental es relevante.

Ejemplo: Efecto de un programa de capacitación (T) sobre el ingreso futuro (Y). Las personas que se inscriben tienden a ser jóvenes, por lo que la edad es una variable de control (backdoor).

Persona	Edad	Educación	Ingreso actual	e(X)
A	25	universitaria	bajo	0.8
B	50	media	alto	0.1
C	26	técnica	bajo	0.78

Para A, $e(X) = 0.8$ significa que entre las personas con el perfil de A, el 80% se inscribe en la capacitación.

Propensity scores

La idea de que el match depende de $e(X)$ implica que el emparejamiento se hace sobre la base de un escalar. Esto ayuda con la maldición de la dimensionalidad.

El propensity score es un *balancing score*.

Definición

Una función de las covariables $b(X)$ es un *balancing score* si el tratamiento es independiente de las covariables condicionando sobre ella:

$$X \perp T \mid b(X),$$

equivalentemente,


$$P(X \mid b(X), T=1) = P(X \mid b(X), T=0).$$



La definición dice algo muy práctico. Si agrupas las unidades por su valor de $b(X)$, dentro de cada grupo las distribuciones de covariables de tratados y controles son idénticas.

Propensity scores

Se puede demostrar que $e(X)$ es un balancing score. Dentro de un estrato de $e(X)$, tratamiento y control es indistinguible.



Desafío: en la práctica el propensity score hay que aprenderlo. Usualmente el propensity score se define a partir de un modelo de clasificación binaria. Se predice T a partir de X y se usa la probabilidad como estimación de $e(X)$.

Propensity scores

Suele usarse regresión logística para estimar $e(X)$:

Modelo

$$e(X) = P(T=1 | X) = \sigma(\beta_0 + \beta^\top X) = \frac{1}{1 + e^{-(\beta_0 + \beta^\top X)}}.$$

La salida $\hat{e}(X) \in (0, 1)$ es la probabilidad estimada de recibir el tratamiento dadas las covariables.

¿Cómo se entrena?

- Datos: Para cada unidad i : covariables X , variable objetivo T en $\{0, 1\}$.
- Ajuste: Se estiman los pesos de la RL por ML:

$$\mathcal{L}(\beta) = - \sum_i \left[T_i \log e(X_i) + (1 - T_i) \log (1 - e(X_i)) \right].$$

Propensity scores

Una vez que tenemos el propensity score model, lo podemos usar de tres formas:

i) **Matching sobre el propensity score:** para cada unidad tratada, se busca uno o más controles con score similar. Eso se puede usar para construir el grupo de controles en matching inexacto. Se calcula ATT.

ii) **Estratificación:** se divide el score en intervalos. Dentro de cada bloque, se estima el efecto por estrato. Típicamente se hace por quintiles ($K=5$). Se puede calcular el efecto sobre los tratados (ATT) o bien sobre el total del estrato (ATE). El efecto global se pondera por el tamaño de cada estrato:

Estimadores agregados

$$\hat{\tau}_{ATE} = \sum_{s=1}^K \frac{N_s}{N} \hat{\tau}_s, \quad \hat{\tau}_{ATT} = \sum_{s=1}^K \frac{N_{1s}}{N_1} \hat{\tau}_s.$$


ATE: pondera por N_s (tamaño del estrato). **ATT:** por N_{1s} (n.º de tratados del estrato).

Propensity scores

iii) **Inverse Probability Weighting (IPW)**: a diferencia de los dos criterios anteriores, en IPW no se empareja sino que se repondera cada unidad en el estimador de efecto. Cada unidad recibe un peso inverso a la probabilidad de tratamiento.

Intuición: un tratado con score bajo (e.g., $e(X) = 0.1$) es una unidad atípica. Pocos como él se trataron así que representa a muchos similares no tratados. Un tratado con score alto (e.g., $e(X) = 0.9$) es un dato típico. Muchos como él se trataron.


La idea de reponderar es ayudar al estimador de efecto a que ATE sea insesgado en relación con el proceso de selección de tratados. Se define:



$$\hat{\tau}_{ATE_{IPW}} = \frac{1}{N_{T=1}} \sum_{i_{T=1}}^{N_{T=1}} \frac{y_i}{\hat{e}(X_i)} - \frac{1}{N_{T=0}} \sum_{j_{T=0}}^{N_{T=0}} \frac{y_j}{1 - \hat{e}(X_j)}$$

Outcome y treatment model

- Una es modelar el resultado sobre la base de tratamiento y covariables. A esto se le denomina **outcome model**.
- La segunda forma es modelar cómo se asignó el tratamiento, que es lo que hacemos con el propensity score. A esto se le denomina **treatment model**.



a) es el modelo de salida, y b) es modelo de tratamiento, introduciendo propensity score.

Outcome model

- **Idea:** El modelo de salida opera sobre el resultado (variable objetivo):

Modelo de resultado (*outcome model*)

$$\mu_t(X) = E[Y \mid T=t, X], \quad t \in \{0, 1\}.$$

Resultado esperado según tratamiento y covariables: $\mu_1(X) = E[Y \mid T=1, X]$ y $\mu_0(X) = E[Y \mid T=0, X]$. Bajo *unconfoundedness*, $\mu_t(X) = E[Y(t) \mid X]$: sirve para predecir el contrafactual.

- Entonces tenemos una ruta alternativa al ATE. Es calcular sobre la base de las estimaciones de resultado dadas por un modelo entrenado (G viene de generalizada):

Estimador (G-computation)

Ajustas $\hat{\mu}_t(X) = E[Y \mid T=t, X]$ (regresión o ML); predices *ambos* resultados para cada unidad y promedias la diferencia:

$$\hat{\tau}_{\text{reg}} = \frac{1}{n} \sum_i [\hat{\mu}_1(X_i) - \hat{\mu}_0(X_i)].$$

Outcome model

- **Entrenamiento:** Si el resultado (Y) es variable continua, se hace regresión. Si es categórico, se entrena un clasificador.

Datos y variable objetivo

Datos: la muestra observada $\{(X_i, T_i, Y_i)\}_{i=1}^n$ (cada fila con su resultado *factual*).

Objetivo: Y (el resultado). A diferencia del treatment model, aquí T pasa a ser *predictor*, no etiqueta.

- Se entrenan dos modelos, uno para resultado sobre tratados y otro para controles:

T-learner

Ajustas *dos modelos separados*, uno por brazo de tratamiento, cada uno entrenado sobre su propia submuestra.

- $\hat{\mu}_1$: entrenado *solo* con los tratados $\{i : T_i=1\}$ — n_1 filas, features X_i , objetivo Y_i .
- $\hat{\mu}_0$: entrenado *solo* con los controles $\{i : T_i=0\}$ — n_0 filas, features X_i , objetivo Y_i .

Doubly Robust (DR)

DR: Podemos trabajar sobre los residuos del modelo de salida (errores). La idea es que el efecto es la predicción del modelo de salida más un error. Ese error pesa más en la medida que el propensity score es mas bajo (es decir, era más difícil tratar esa unidad).

Averaging

$$\hat{\tau}_{ATE} = \frac{1}{N} \sum_i \left(\underbrace{\frac{T_i(Y_i - \mu_1(X_i))}{\hat{e}(X_i)} + \mu_1(X_i)}_{\mu_1 = \text{model with treatment}} \right) - \frac{1}{N} \sum_i \left(\underbrace{\frac{(1 - T_i)(Y_i - \mu_0(X_i))}{1 - \hat{e}(X_i)} + \mu_0(X_i)}_{\mu_0 = \text{model without treatment}} \right)$$

¿Por qué el residuo del dato atípico pesa más en ATE?

Ese dato es importante porque es el único testigo del error del modelo de salida en una región donde casi nadie se trató.